Datan suodattaminen ja lajittelu

1–2. Datan lataaminen ja 20 ensimmäistä riviä

```
import seaborn as sns
import pandas as pd
import matplotlib.pyplot as plt

df = sns.load_dataset("titanic")

print(df.head(20).to_string())
```

```
    survived  pclass     sex   age  sibsp  parch     fare embarked   class    who  adult_male deck  embark_town alive  alone
0          0       3    male  22.0      1      0   7.2500        S   Third    man        True  NaN  Southampton    no  False
1          1       1  female  38.0      1      0  71.2833        C   First  woman       False    C    Cherbourg   yes  False
2          1       3  female  26.0      0      0   7.9250        S   Third  woman       False  NaN  Southampton   yes   True
3          1       1  female  35.0      1      0  53.1000        S   First  woman       False    C  Southampton   yes  False
4          0       3    male  35.0      0      0   8.0500        S   Third    man        True  NaN  Southampton    no   True
5          0       3    male   NaN      0      0   8.4583        Q   Third    man        True  NaN   Queenstown    no   True
6          0       1    male  54.0      0      0  51.8625        S   First    man        True    E  Southampton    no   True
7          0       3    male   2.0      3      1  21.0750        S   Third  child       False  NaN  Southampton    no  False
8          1       3  female  27.0      0      2  11.1333        S   Third  woman       False  NaN  Southampton   yes  False
9          1       2  female  14.0      1      0  30.0708        C  Second  child       False  NaN    Cherbourg   yes  False
10         1       3  female   4.0      1      1  16.7000        S   Third  child       False    G  Southampton   yes  False
11         1       1  female  58.0      0      0  26.5500        S   First  woman       False    C  Southampton   yes   True
12         0       3    male  20.0      0      0   8.0500        S   Third    man        True  NaN  Southampton    no   True
13         0       3    male  39.0      1      5  31.2750        S   Third    man        True  NaN  Southampton    no  False
14         0       3  female  14.0      0      0   7.8542        S   Third  child       False  NaN  Southampton    no   True
15         1       2  female  55.0      0      0  16.0000        S  Second  woman       False  NaN  Southampton   yes   True
16         0       3    male   2.0      4      1  29.1250        Q   Third  child       False  NaN   Queenstown    no  False
17         1       2    male   NaN      0      0  13.0000        S  Second    man        True  NaN  Southampton   yes   True
18         0       3  female  31.0      1      0  18.0000        S   Third  woman       False  NaN  Southampton    no  False
19         1       3  female   NaN      0      0   7.2250        C   Third  woman       False  NaN    Cherbourg   yes   True
```

3. Kolme erilaista suodatusta

```
# Suodatetaan yli 60-vuotiaat
print("Yli 60-vuotiaat matkustajat:")
print(df[df["age"] > 60].head(8).to_string())

# Suodatetaan ykkösluokka
print("\nEnsimmäisen luokan matkustajat:")
print(df[df["class"] == "First"].head(8).to_string())

# Kahden ehdon suodatus: ykkösluokka ja hengissä selvinneet
print("\nEnsimmäisen luokan hengissä selvinneet:")
print(df[(df["class"] == "First") & (df["survived"] == 1)].head(8).to_string())
```

```
Yli 60-vuotiaat matkustajat:
     survived  pclass     sex   age  sibsp  parch     fare embarked   class    who  adult_male deck  embark_town alive  alone
33          0       2    male  66.0      0      0  10.5000        S  Second    man        True  NaN  Southampton    no   True
54          0       1    male  65.0      0      1  61.9792        C   First    man        True    B    Cherbourg    no  False
96          0       1    male  71.0      0      0  34.6542        C   First    man        True    A    Cherbourg    no   True
116         0       3    male  70.5      0      0   7.7500        Q   Third    man        True  NaN   Queenstown    no   True
170         0       1    male  61.0      0      0  33.5000        S   First    man        True    B  Southampton    no   True
252         0       1    male  62.0      0      0  26.5500        S   First    man        True    C  Southampton    no   True
275         1       1  female  63.0      1      0  77.9583        S   First  woman       False    D  Southampton   yes  False
280         0       3    male  65.0      0      0   7.7500        Q   Third    man        True  NaN   Queenstown    no   True

Ensimmäisen luokan matkustajat:
    survived  pclass     sex   age  sibsp  parch     fare embarked  class    who  adult_male deck  embark_town alive  alone
1          1       1  female  38.0      1      0  71.2833        C  First  woman       False    C    Cherbourg   yes  False
3          1       1  female  35.0      1      0  53.1000        S  First  woman       False    C  Southampton   yes  False
6          0       1    male  54.0      0      0  51.8625        S  First    man        True    E  Southampton    no   True
11         1       1  female  58.0      0      0  26.5500        S  First  woman       False    C  Southampton   yes   True
23         1       1    male  28.0      0      0  35.5000        S  First    man        True    A  Southampton   yes   True
27         0       1    male  19.0      3      2  263.0000       S  First    man        True    C  Southampton    no  False
30         0       1    male  40.0      0      0  27.7208        C  First    man        True  NaN    Cherbourg    no   True
31         1       1  female   NaN      1      0  146.5208       C  First  woman       False    B    Cherbourg   yes  False

Ensimmäisen luokan hengissä selvinneet:
    survived  pclass     sex   age  sibsp  parch     fare embarked  class    who  adult_male deck  embark_town alive  alone
1          1       1  female  38.0      1      0  71.2833        C  First  woman       False    C    Cherbourg   yes  False
3          1       1  female  35.0      1      0  53.1000        S  First  woman       False    C  Southampton   yes  False
11         1       1  female  58.0      0      0  26.5500        S  First  woman       False    C  Southampton   yes   True
23         1       1    male  28.0      0      0  35.5000        S  First    man        True    A  Southampton   yes   True
31         1       1  female   NaN      1      0  146.5208       C  First  woman       False    B    Cherbourg   yes  False
52         1       1  female  49.0      1      0  76.7292        C  First  woman       False    D    Cherbourg   yes  False
55         1       1    male   NaN      0      0  35.5000        S  First    man        True    C  Southampton   yes   True
61         1       1  female  38.0      0      0  80.0000      NaN  First  woman       False    B          NaN   yes   True
```

4. Lajittelu kahdella ehdolla

```
# Hinta laskevasti ja ikä nousevasti
lajiteltu = df.sort_values(by=["fare", "age"],ascending=[False, True])

print(lajiteltu.head(25).to_string())
```

	survived	pclass	sex	age	sibsp	parch	fare	embarked	class	who	adult_male	deck	embark_town	alive	alone
258	1	1	female	35.0	0	0	512.3292	C	First	woman	False	NaN	Cherbourg	yes	True
737	1	1	male	35.0	0	0	512.3292	C	First	man	True	B	Cherbourg	yes	True
679	1	1	male	36.0	0	1	512.3292	C	First	man	True	B	Cherbourg	yes	False
27	0	1	male	19.0	3	2	263.0000	S	First	man	True	C	Southampton	no	False
88	1	1	female	23.0	3	2	263.0000	S	First	woman	False	C	Southampton	yes	False
341	1	1	female	24.0	3	2	263.0000	S	First	woman	False	C	Southampton	yes	False
438	0	1	male	64.0	1	4	263.0000	S	First	man	True	C	Southampton	no	False
311	1	1	female	18.0	2	2	262.3750	C	First	woman	False	B	Cherbourg	yes	False
742	1	1	female	21.0	2	2	262.3750	C	First	woman	False	B	Cherbourg	yes	False
118	0	1	male	24.0	0	1	247.5208	C	First	man	True	B	Cherbourg	no	False
299	1	1	female	50.0	0	1	247.5208	C	First	woman	False	B	Cherbourg	yes	False
700	1	1	female	18.0	1	0	227.5250	C	First	woman	False	C	Cherbourg	yes	False
716	1	1	female	38.0	0	0	227.5250	C	First	woman	False	C	Cherbourg	yes	True
380	1	1	female	42.0	0	0	227.5250	C	First	woman	False	NaN	Cherbourg	yes	True
557	0	1	male	NaN	0	0	227.5250	C	First	man	True	NaN	Cherbourg	no	True
527	0	1	male	NaN	0	0	221.7792	S	First	man	True	C	Southampton	no	True
377	0	1	male	27.0	0	2	211.5000	C	First	man	True	C	Cherbourg	no	False
689	1	1	female	15.0	0	1	211.3375	S	First	child	False	B	Southampton	yes	False
730	1	1	female	29.0	0	0	211.3375	S	First	woman	False	B	Southampton	yes	True
779	1	1	female	43.0	0	1	211.3375	S	First	woman	False	B	Southampton	yes	False
318	1	1	female	31.0	0	2	164.8667	S	First	woman	False	C	Southampton	yes	False
856	1	1	female	45.0	1	1	164.8667	S	First	woman	False	NaN	Southampton	yes	False
332	0	1	male	38.0	0	1	153.4625	S	First	man	True	C	Southampton	no	False
609	1	1	female	40.0	0	0	153.4625	S	First	woman	False	C	Southampton	yes	True
268	1	1	female	58.0	0	1	153.4625	S	First	woman	False	C	Southampton	yes	False

5. Uusi dataframe valituista sarakkeista

```
# Uusi dataframe valituista sarakkeista. Valitaan analyysiin tarvittavat sarakkeet
df2 = df[["survived", "pclass", "age", "fare"]].copy()

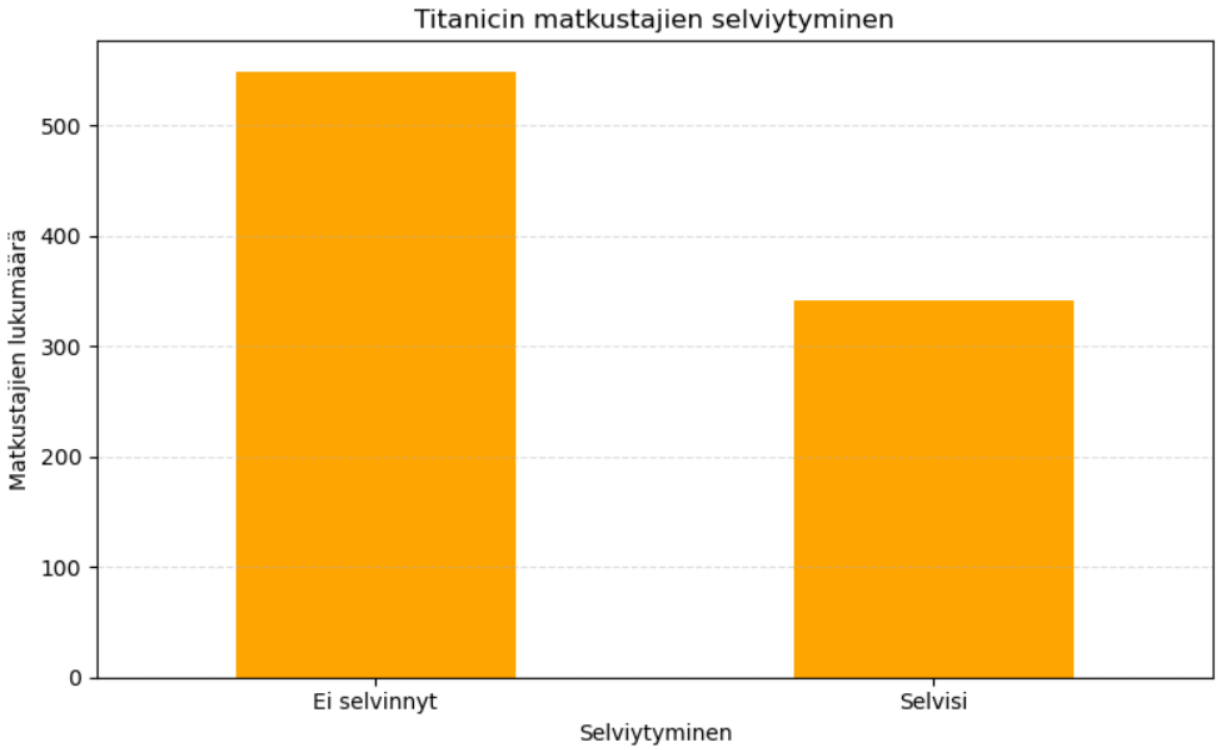
print(df2.head(20).to_string())
```

	survived	pclass	age	fare
0	0	3	22.0	7.2500
1	1	1	38.0	71.2833
2	1	3	26.0	7.9250
3	1	1	35.0	53.1000
4	0	3	35.0	8.0500
5	0	3	NaN	8.4583
6	0	1	54.0	51.8625
7	0	3	2.0	21.0750
8	1	3	27.0	11.1333
9	1	2	14.0	30.0708
10	1	3	4.0	16.7000
11	1	1	58.0	26.5500
12	0	3	20.0	8.0500
13	0	3	39.0	31.2750
14	0	3	14.0	7.8542
15	1	2	55.0	16.0000
16	0	3	2.0	29.1250
17	1	2	NaN	13.0000
18	0	3	31.0	18.0000
19	1	3	NaN	7.2250

6a. Pylväskaavio

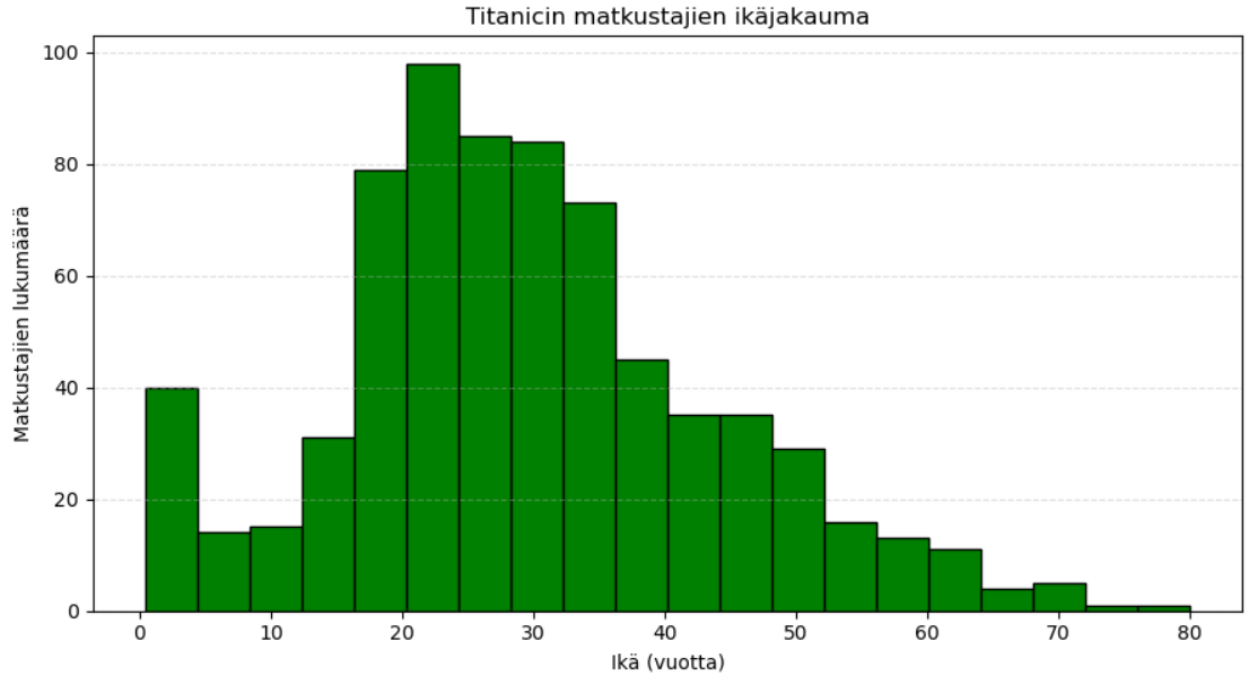
```
# Pylväskaavio selviytyneistä
selviytyneet = df2["survived"].replace({
    0: "Ei selvinnyt",
    1: "Selvisi"
}).value_counts()

plt.figure(figsize=(8, 5))
selviytyneet.plot(kind="bar", color="orange")
plt.title("Titanicin matkustajien selviytyminen")
plt.xlabel("Selviytyminen")
plt.ylabel("Matkustajien lukumäärä")
plt.grid(axis="y", linestyle="--", alpha=0.4)
plt.xticks(rotation=0)
plt.tight_layout()
plt.show()
```



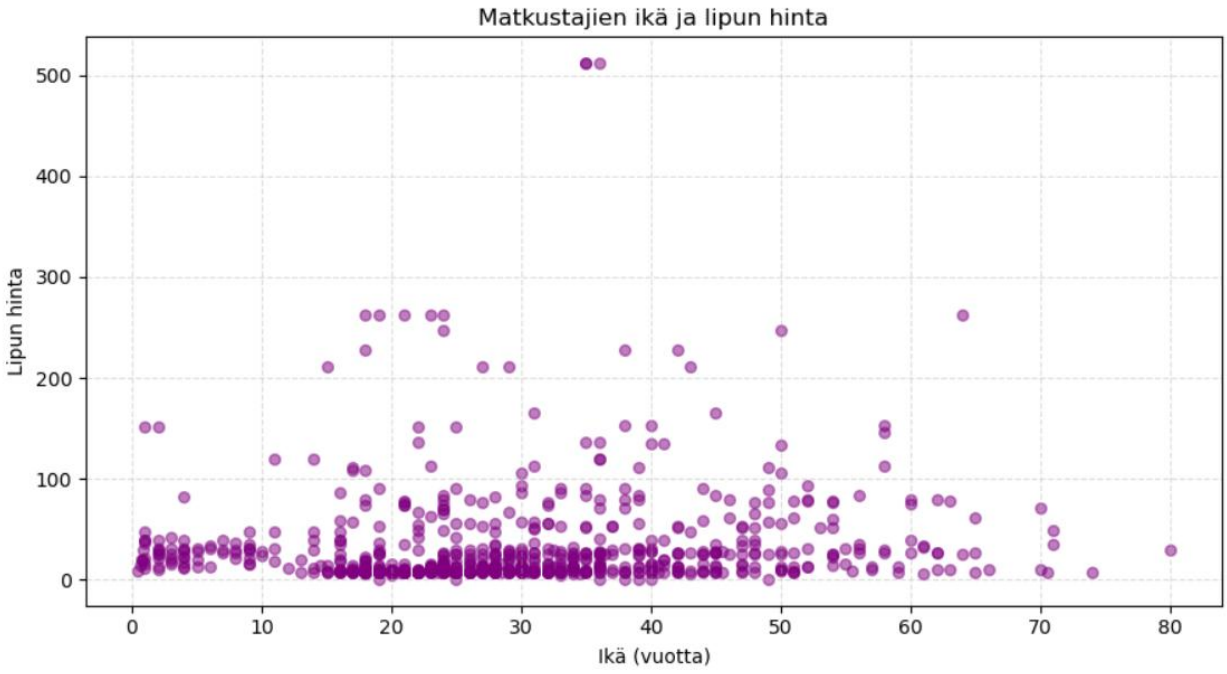
6b. Histogrammi

```
# Histogrammi matkustajien iästä
plt.figure(figsize=(9, 5))
plt.hist(df2["age"].dropna(), bins=20, color="green", edgecolor="black")
plt.title("Titanicin matkustajien ikäjakauma")
plt.xlabel("Ikä (vuotta)")
plt.ylabel("Matkustajien lukumäärä")
plt.grid(axis="y", linestyle="--", alpha=0.4)
plt.tight_layout()
plt.show()
```



6c. Hajontakaavio

```
# Hajontakaavio matkustajien iät ja lipun hinta
plt.figure(figsize=(9, 5))
plt.scatter(df2["age"], df2["fare"],
            color="purple", alpha=0.5, s=30)
plt.title("Matkustajien ikä ja lipun hinta")
plt.xlabel("Ikä (vuotta)")
plt.ylabel("Lipun hinta")
plt.grid(linestyle="--", alpha=0.4)
plt.tight_layout()
plt.show()
```



7. Yhteenveto

Kaaviosta nähdään, että suurin osa Titanicin matkustajista ei selvinnyt: eloonjääneitä oli noin 340 ja menehtyneitä noin 550. Ikäjakauma painottuu nuoriin aikuisiin, ja yleisimmät iät ovat noin 20–40 vuotta. Lisäksi alle 5-vuotiaiden lasten ryhmä erottuu histogrammissa omana pienenä huippunaan. Hajontakaaviosta nähdään, että suurin osa lipuista oli edullisia iästä riippumatta, ja kalliimpia yli 200 hintaisia lippuja oli vain muutamilla matkustajilla. Selvää yhteyttä iän ja lipun hinnan välillä ei näytä olevan.

Huomio tulosteista: Osa suodatuksista on rajattu head()-komennolla, jotta ne mahtuvat siististi ja selkeälukuisesti yhteen kuvakaappaukseen. Koko suodatettu aineisto olisi ollut liian pitkä luettavaksi, mutta suodatukset toimivat koko aineistoon.