Datan ryhmittely ja yhdistäminen

1. Aineiston ja muuttujien esittely

Analyysissä käytetään Video Game Sales -aineistoa, joka sisältää 16 598 videopelin myyntitietoja. Aineistossa on tietoja esimerkiksi pelien nimistä, julkaisuvuosista, pelialustoista, genreistä ja myyntimääristä eri alueilla.

Analyysissä käytetään seuraavia muuttujia:

Genre: Pelin lajityyppi, esimerkiksi Action, Sports tai Platform.
Platform: Pelialusta, esimerkiksi PS2, Wii tai X360.
Year: Pelin julkaisuvuosi.
Global_Sales: Pelin maailmanlaajuinen myynti miljoonina kappaleina.
NA_Sales: Myynti Pohjois-Amerikassa.
EU_Sales: Myynti Euroopassa.
JP_Sales: Myynti Japanissa.
Other_Sales: Myynti muilla alueilla.

Tavoitteena on tutkia peligenrejen yleisyyttä sekä vertailla pelien myyntimääriä eri genrejen, alustojen ja myyntialueiden välillä.

```
import pandas as pd

url = "https://gist.githubusercontent.com/zhonglism/f146a9423e2c975de8d03c26451f841e/raw/vgsales.csv"

df = pd.read_csv(url)

print("Aineiston koko:", df.shape)
print("\nEnsimmäiset 10 riviä:")
print(df.head(10).to_string(index=False))
print("\nSarakkeet:")
print(df.columns.tolist())
```

```
Aineiston koko: (16598, 11)

Ensimmäiset 10 riviä:
 Rank                     Name Platform   Year        Genre Publisher  NA_Sales  EU_Sales  JP_Sales  Other_Sales  Global_Sales
    1               Wii Sports      Wii 2006.0       Sports  Nintendo     41.49     29.02      3.77         8.46         82.74
    2        Super Mario Bros.      NES 1985.0     Platform  Nintendo     29.08      3.58      6.81         0.77         40.24
    3           Mario Kart Wii      Wii 2008.0       Racing  Nintendo     15.85     12.88      3.79         3.31         35.82
    4        Wii Sports Resort      Wii 2009.0       Sports  Nintendo     15.75     11.01      3.28         2.96         33.00
    5  Pokemon Red/Pokemon Blue       GB 1996.0 Role-Playing  Nintendo     11.27      8.89     10.22         1.00         31.37
    6                   Tetris       GB 1989.0       Puzzle  Nintendo     23.20      2.26      4.22         0.58         30.26
    7    New Super Mario Bros.       DS 2006.0     Platform  Nintendo     11.38      9.23      6.50         2.90         30.01
    8                 Wii Play      Wii 2006.0         Misc  Nintendo     14.03      9.20      2.93         2.85         29.02
    9 New Super Mario Bros. Wii      Wii 2009.0     Platform  Nintendo     14.59      7.06      4.70         2.26         28.62
   10                Duck Hunt      NES 1984.0      Shooter  Nintendo     26.93      0.63      0.28         0.47         28.31

Sarakkeet:
['Rank', 'Name', 'Platform', 'Year', 'Genre', 'Publisher', 'NA_Sales', 'EU_Sales', 'JP_Sales', 'Other_Sales', 'Global_Sales']
```

2. Peligenrejen frekvenssitaulukko

```
# Peligenrejen frekvenssitaulukko
frekvenssi = df["Genre"].value_counts().sort_index()

taulukko = pd.DataFrame({"Frekvenssi": frekvenssi})

taulukko["Kumulatiivinen frekvenssi"] = taulukko["Frekvenssi"].cumsum()
taulukko["Suhteellinen frekvenssi (%)"] = (
    taulukko["Frekvenssi"] / taulukko["Frekvenssi"].sum() * 100).round(2)

taulukko["Kumulatiivinen suhteellinen frekvenssi (%)"] = (
    taulukko["Frekvenssi"].cumsum() / taulukko["Frekvenssi"].sum() * 100).round(2)

# Yhteenvetorivi
taulukko.loc["Yhteensä"] = [taulukko["Frekvenssi"].sum(),taulukko["Frekvenssi"].sum(),100.0,100.0]

print(taulukko.to_string())
```

```
             Frekvenssi  Kumulatiivinen frekvenssi  Suhteellinen frekvenssi (%)  Kumulatiivinen suhteellinen frekvenssi (%)
Genre
Action           3316.0                     3316.0                        19.98                                       19.98
Adventure        1286.0                     4602.0                         7.75                                       27.73
Fighting          848.0                     5450.0                         5.11                                       32.84
Misc             1739.0                     7189.0                        10.48                                       43.31
Platform          886.0                     8075.0                         5.34                                       48.65
Puzzle            582.0                     8657.0                         3.51                                       52.16
Racing           1249.0                     9906.0                         7.53                                       59.68
Role-Playing     1488.0                    11394.0                         8.96                                       68.65
Shooter          1310.0                    12704.0                         7.89                                       76.54
Simulation        867.0                    13571.0                         5.22                                       81.76
Sports           2346.0                    15917.0                        14.13                                       95.90
Strategy          681.0                    16598.0                         4.10                                      100.00
Yhteensä        16598.0                    16598.0                       100.00                                      100.00
```

3. Maailmanlaajuisten myyntimäärien luokittelu

Pelit jaetaan viiteen luokkaan maailmanlaajuisen myyntimäärän perusteella. Myyntimäärät ilmoitetaan miljoonina kappaleina.

Luokkarajat ovat:

- Alle 0,1 miljoonaa
- 0,1–alle 0,5 miljoonaa
- 0,5–alle 1 miljoonaa
- 1–alle 5 miljoonaa
- Vähintään 5 miljoonaa

Luokkarajat valittiin, koska pelien myyntimäärät vaihtelevat huomattavasti. Pienille myyntimäärille käytetään tarkempia luokkia, kun taas suuria myyntimääriä yhdistetään laajempiin luokkiin. Näin voidaan vertailla vähemmän myytyjä pelejä ja suuria myyntimenestyksiä.

```
# Myyntimäärien luokittelu
rajat = [0, 0.1, 0.5, 1, 5, float("inf")]

nimet = ["Alle 0,1 milj.","0,1–alle 0,5 milj.","0,5–alle 1 milj.","1–alle 5 milj.","Vähintään 5 milj."]

df["Myyntiluokka"] = pd.cut(df["Global_Sales"],bins=rajat,labels=nimet,right=False,include_lowest=True)

# Frekvenssitaulukko myyntiluokista
myyntifrekvenssi = df["Myyntiluokka"].value_counts().sort_index()

myyntitaulukko = pd.DataFrame({"Frekvenssi": myyntifrekvenssi})

myyntitaulukko["Kumulatiivinen frekvenssi"] = (myyntitaulukko["Frekvenssi"].cumsum())

myyntitaulukko["Suhteellinen frekvenssi (%)"] = (myyntitaulukko["Frekvenssi"]/ myyntitaulukko["Frekvenssi"].sum() * 100).round(2)

myyntitaulukko["Kumulatiivinen suhteellinen frekvenssi (%)"] = (
    myyntitaulukko["Frekvenssi"].cumsum()/ myyntitaulukko["Frekvenssi"].sum() * 100).round(2)

myyntitaulukko.loc["Yhteensä"] = [myyntitaulukko["Frekvenssi"].sum(),myyntitaulukko["Frekvenssi"].sum(),100.0,100.0]

print(myyntitaulukko.to_string())
```

```
                  Frekvenssi  Kumulatiivinen frekvenssi  Suhteellinen frekvenssi (%)  Kumulatiivinen suhteellinen frekvenssi (%)
Myyntiluokka
Alle 0,1 milj.        5781.0                     5781.0                        34.83                                       34.83
0,1–alle 0,5 milj.    6799.0                    12580.0                        40.96                                       75.79
0,5–alle 1 milj.      1937.0                    14517.0                        11.67                                       87.46
1–alle 5 milj.        1874.0                    16391.0                        11.29                                       98.75
Vähintään 5 milj.      207.0                    16598.0                         1.25                                      100.00
Yhteensä             16598.0                    16598.0                       100.00                                      100.00
```

4. Peligenren ja myyntiluokan ristiintaulukointi

```
Ristiintaulukoinnilla tarkastellaan, miten pelit jakautuvat eri myyntiluokkiin peligenren perusteella.
Taulukon riveillä esitetään peligenret ja sarakkeissa maailmanlaajuisen myynnin luokat.
Lisäksi lasketaan yhteensä-rivit ja -sarakkeet.
```

```python
# Peligenren ja myyntiluokan ristiintaulukointi
ristiintaulukko = pd.crosstab(
    df["Genre"],
    df["Myyntiluokka"],
    margins=True,
    margins_name="Yhteensä"
)

print(ristiintaulukko.to_string())
```

```
Myyntiluokka  Alle 0,1 milj.  0,1-alle 0,5 milj.  0,5-alle 1 milj.  1-alle 5 milj.  Vähintään 5 milj.  Yhteensä
Genre
Action                 1045                1436               409             389                  37      3316
Adventure               808                 381                55              40                   2      1286
Fighting                243                 372               109             116                   8       848
Misc                    622                 765               179             158                  15      1739
Platform                231                 342               118             162                  33       886
Puzzle                  278                 205                43              50                   6       582
Racing                  393                 528               146             166                  16      1249
Role-Playing            497                 601               187             173                  30      1488
Shooter                 389                 483               186             216                  36      1310
Simulation              333                 351                90              86                   7       867
Sports                  600                1084               359             288                  15      2346
Strategy                342                 251                56              30                   2       681
Yhteensä               5781                6799              1937            1874                 207     16598
```

```python
print("Yleisin peligenre:")
print(df["Genre"].value_counts().head(1).to_string())

print("\nMyyntiluokkien jakauma:")
print(df["Myyntiluokka"].value_counts().sort_index().to_string())

print("\nVähintään 5 miljoonaa myyneet pelit genreittäin:")
print(ristiintaulukko.drop(index="Yhteensä")["Vähintään 5 milj."]
    .sort_values(ascending=False).head(5).to_string())
```

```
Yleisin peligenre:
Genre
Action    3316

Myyntiluokkien jakauma:
Myyntiluokka
Alle 0,1 milj.        5781
0,1-alle 0,5 milj.    6799
0,5-alle 1 milj.      1937
1-alle 5 milj.        1874
Vähintään 5 milj.      207

Vähintään 5 miljoonaa myyneet pelit genreittäin:
Genre
Action          37
Shooter         36
Platform        33
Role-Playing    30
Racing          16
```

5. Kohtien 2-4 tulokset

```
Aineiston yleisin peligenre on Action, johon kuuluu 3316 peliä.

Myyntiluokkien perusteella suurin osa peleistä on myynyt alle 0,5 miljoonaa kappaletta maailmanlaajuisesti.
Näitä pelejä on yhteensä 12 580 eli noin 75,8 % aineistosta.
Vähintään viisi miljoonaa kappaletta myyneitä pelejä on puolestaan vain 207 eli noin 1,2 %.

Ristiintaulukoinnista nähdään, että vähintään viisi miljoonaa kappaletta myyneitä pelejä on eniten Action-genressä (37 peliä),
Shooter-genressä (36 peliä) ja Platform-genressä (33 peliä).

Tulokset osoittavat, että suuria myyntimenestyksiä on suhteellisen vähän ja pelien myyntimäärät jakautuvat epätasaisesti.
```

6. Ryhmittely peligenren perusteella

```
Pelit ryhmitellään genren mukaan. Jokaiselle genrelle lasketaan pelien lukumäärä, maailmanlaajuisen myynnin keskiarvo,
mediaani, summa ja suurin myyntimäärä. Näin voidaan vertailla eri genrejen myyntiä.
```

```python
# Ryhmittely genren perusteella
genre_ryhmittely = df.groupby("Genre").agg(Pelien_maara=("Global_Sales", "count"),
    Keskiarvo=("Global_Sales", "mean"),Mediaani=("Global_Sales", "median"),
    Kokonaismyynti=("Global_Sales", "sum"),Suurin_myynti=("Global_Sales", "max"))

genre_ryhmittely = genre_ryhmittely.round(2)
print(genre_ryhmittely.to_string())
```

Genre	Pelien_maara	Keskiarvo	Mediaani	Kokonaismyynti	Suurin_myynti
Action	3316	0.53	0.19	1751.18	21.40
Adventure	1286	0.19	0.06	239.04	11.18
Fighting	848	0.53	0.21	448.91	13.04
Misc	1739	0.47	0.16	809.96	29.02
Platform	886	0.94	0.28	831.37	40.24
Puzzle	582	0.42	0.11	244.95	30.26
Racing	1249	0.59	0.19	732.04	35.82
Role-Playing	1488	0.62	0.18	927.37	31.37
Shooter	1310	0.79	0.23	1037.37	28.31
Simulation	867	0.45	0.16	392.20	24.76
Sports	2346	0.57	0.22	1330.93	82.74
Strategy	681	0.26	0.09	175.12	5.45

7-8. Ryhmittely pelialustan ja genren perusteella

Aineistosta valitaan PS2-, Wii- ja X360-pelit. Pelit ryhmitellään alustan ja genren mukaan, minkä jälkeen lasketaan ryhmien pelimäärät sekä maailmanlaajuisen myynnin keskiarvo, mediaani ja kokonaismyynti.

Tavoitteena on vertailla, miten eri peligenret ovat menestyneet näillä kolmella alustalla.

```
# Valitaan kolme pelialustaa
valitut = df[df["Platform"].isin(["PS2", "Wii", "X360"])]

# Ryhmittely alustan ja genren mukaan
alusta_genre = valitut.groupby(["Platform", "Genre"]).agg(
    Pelien_maara=("Global_Sales", "count"),
    Keskiarvo=("Global_Sales", "mean"),
    Mediaani=("Global_Sales", "median"),
    Kokonaismyynti=("Global_Sales", "sum")
)

alusta_genre = alusta_genre.round(2)

print(alusta_genre.to_string())
```

Platform	Genre	Pelien_maara	Keskiarvo	Mediaani	Kokonaismyynti
PS2	Action	348	0.78	0.35	272.76
	Adventure	196	0.11	0.03	21.16
	Fighting	150	0.62	0.22	92.60
	Misc	222	0.46	0.22	101.14
	Platform	103	0.70	0.40	72.51
	Puzzle	18	0.33	0.14	5.90
	Racing	216	0.72	0.26	156.28
	Role-Playing	187	0.50	0.20	93.50
	Shooter	160	0.68	0.28	108.57
	Simulation	90	0.47	0.23	42.66
	Sports	400	0.68	0.32	273.41
	Strategy	71	0.21	0.11	15.15
Wii	Action	238	0.50	0.24	118.58
	Adventure	84	0.22	0.12	18.43
	Fighting	42	0.57	0.15	23.86
	Misc	280	0.79	0.24	221.06
	Platform	58	1.56	0.32	90.74
	Puzzle	55	0.28	0.12	15.67
	Racing	94	0.65	0.15	61.28
	Role-Playing	35	0.40	0.25	14.06
	Shooter	66	0.44	0.12	28.77
	Simulation	87	0.42	0.23	36.97
	Sports	261	1.12	0.23	292.06
	Strategy	25	0.21	0.15	5.23
X360	Action	324	0.75	0.30	242.67
	Adventure	47	0.32	0.06	15.23
	Fighting	65	0.58	0.36	37.64
	Misc	126	0.73	0.21	91.96
	Platform	24	0.47	0.30	11.39
	Puzzle	7	0.12	0.11	0.85
	Racing	105	0.63	0.26	65.99
	Role-Playing	76	0.95	0.33	71.98
	Shooter	203	1.37	0.41	278.55
	Simulation	40	0.36	0.20	14.45
	Sports	220	0.63	0.30	139.12
	Strategy	28	0.36	0.26	10.13

9. Pivot-taulukko peligenrejen alueellisesta myynnistä

Pivot-taulukossa vertaillaan eri peligenrejen kokonaismyyntiä Pohjois-Amerikassa, Euroopassa, Japanissa ja muilla alueilla.

Aggregointifunktiona käytetään summaa, koska tarkoituksena on selvittää, kuinka monta miljoonaa peliä kussakin genressä on myyty eri alueilla. Taulukkoon lisätään myös yhteenvetorivi.

```
# Pivot-taulukko genrejen alueellisesta myynnistä
pivot = pd.pivot_table(df,index="Genre",
    values=["NA_Sales", "EU_Sales", "JP_Sales", "Other_Sales"],aggfunc="sum",margins=True,margins_name="Yhteensä")

# Järjestetään sarakkeet
pivot = pivot[["NA_Sales", "EU_Sales", "JP_Sales", "Other_Sales"]]

print(pivot.round(2).to_string())
```

Genre	NA_Sales	EU_Sales	JP_Sales	Other_Sales
Action	877.83	525.00	159.95	187.38
Adventure	105.80	64.13	52.07	16.81
Fighting	223.59	101.32	87.35	36.68
Misc	410.24	215.98	107.76	75.32
Platform	447.05	201.63	130.77	51.59
Puzzle	123.78	50.78	57.31	12.55
Racing	359.42	238.39	56.69	77.27
Role-Playing	327.28	188.06	352.31	59.61
Shooter	582.60	313.27	38.28	102.69
Simulation	183.31	113.38	63.70	31.52
Sports	683.35	376.85	135.37	134.97
Strategy	68.70	45.34	49.46	11.36
Yhteensä	4392.95	2434.13	1291.02	797.75

10. Kohtien 6-9 tulokset

Yhden muuttujan ryhmittelyssä huomattiin, että Action-genren kokonaismyynti oli suurin, 1751,18 miljoonaa kappaletta. Se oli myös pelimäärältään suurin genre (3316 peliä). Platform-genren keskimääräinen myynti oli korkein, 0,94 miljoonaa kappaletta peliä kohden. Adventure-genren keskimääräinen myynti oli puolestaan pienin, 0,19 miljoonaa kappaletta.

Kahden muuttujan ryhmittelyssä havaittiin eroja eri pelialustojen välillä. PlayStation 2:lla Sports-genren kokonaismyynti oli suurin (273,41 miljoonaa), kun taas Wiillä Sports-genren kokonaismyynti oli 292,06 miljoonaa. Xbox 360:lla Shooter-genre oli suurin 278,55 miljoonan kappaleen kokonaismyynnillä. Wiillä Platform-genren keskimääräinen myynti oli erityisen korkea, 1,56 miljoonaa kappaletta peliä kohden.

Pivot-taulukon perusteella Pohjois-Amerikka oli aineiston suurin myyntialue, jossa pelejä myytiin yhteensä 4392,95 miljoonaa kappaletta. Euroopassa myynti oli 2434,13 miljoonaa ja Japanissa 1291,02 miljoonaa kappaletta.

Action-genren myynti oli suurinta Pohjois-Amerikassa (877,83 miljoonaa). Japanissa puolestaan Role-Playing-genren myynti (352,31 miljoonaa) oli suurempaa kuin minkään muun genren.

Tulosten perusteella pelien myyntimäärissä oli huomattavia eroja genrejen, pelialustojen ja maantieteellisten alueiden välillä.