Datan puhdistus ja esikasittely

November 7, 2026

Tehtävä 1: Elokuva-aineiston lataaminen

Käytän tehtävässä Movie Industry -elokuva-aineistoa. Se sisältää elokuvien nimiä, genrejä, ohjaajia, julkaisuvuosia, arvosanoja, budjetteja ja lipputuloja.

Tavoitteena on selvittää aineiston mahdolliset laatuongelmat, tehdä tarvittavat puhdistustoimenpiteet ja verrata puhdistettua aineistoa alkuperäiseen.

[1]:
```
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

url = "https://raw.githubusercontent.com/Juanets/movie-stats/master/movies.csv"

df = pd.read_csv(url)
df_original = df.copy()

print("Aineiston koko:", df.shape)
print("\nEnsimmäiset 10 riviä:")
print(df.head(10).to_string(index=False))
```

```
Aineiston koko: (7668, 15)

Ensimmäiset 10 riviä:
                                       name rating     genre  year
released  score     votes           director                writer
star        country     budget       gross                    company  runtime
                                The Shining      R     Drama  1980     June
13, 1980 (United States)    8.4  927000.0    Stanley Kubrick            Stephen
King  Jack Nicholson United Kingdom 19000000.0  46998772.0
Warner Bros.    146.0
                             The Blue Lagoon      R Adventure  1980      July
2, 1980 (United States)    5.8   65000.0     Randal Kleiser Henry De Vere
Stacpoole  Brooke Shields  United States  4500000.0  58853106.0
Columbia Pictures    104.0
Star Wars: Episode V - The Empire Strikes Back     PG    Action  1980     June
20, 1980 (United States)    8.7 1200000.0     Irvin Kershner          Leigh
Brackett     Mark Hamill  United States 18000000.0 538375067.0
Lucasfilm    124.0
```

```
                                    Airplane!     PG    Comedy  1980      July
2, 1980 (United States)    7.7  221000.0       Jim Abrahams            Jim
Abrahams     Robert Hays  United States  3500000.0  83453539.0
Paramount Pictures     88.0
                                  Caddyshack      R    Comedy  1980     July
25, 1980 (United States)    7.3  108000.0       Harold Ramis      Brian Doyle-
Murray     Chevy Chase  United States  6000000.0  39846344.0              Orion
Pictures     98.0
                               Friday the 13th      R    Horror  1980       May
9, 1980 (United States)    6.4  123000.0 Sean S. Cunningham           Victor
Miller    Betsy Palmer  United States   550000.0  39754601.0           Paramount
Pictures     95.0
                             The Blues Brothers      R    Action  1980     June
20, 1980 (United States)    7.9  188000.0        John Landis             Dan
Aykroyd    John Belushi  United States 27000000.0 115229890.0
Universal Pictures    133.0
                                   Raging Bull      R Biography  1980 December
19, 1980 (United States)    8.2  330000.0    Martin Scorsese            Jake
LaMotta  Robert De Niro  United States 18000000.0  23402427.0 Chartoff-Winkler
Productions    129.0
                                   Superman II     PG    Action  1980     June
19, 1981 (United States)    6.8  101000.0     Richard Lester            Jerry
Siegel    Gene Hackman  United States 54000000.0 108185706.0
Dovemead Films    127.0
                               The Long Riders      R Biography  1980      May
16, 1980 (United States)    7.0   10000.0        Walter Hill             Bill
Bryden David Carradine  United States 10000000.0  15795189.0
United Artists    100.0
```

Tehtävä 2: Aineiston rakenteen ja laatuongelmien tutkiminen

Aineistosta tutkitaan sarakkeiden tietotyypit, puuttuvat arvot, duplikaatit, tekstimuuttujien kirjoitusasut sekä mahdolliset virheelliset tai huonot arvot.

Tässä vaiheessa aineistoa ei vielä lähdetä muuttamaan, vaan tarkoituksena on selvittää, millaisia puhdistustoimenpiteitä tarvitaan.

[2]:
```python
# Aineiston rakenne ja tietotyypit
print("Aineiston koko:", df.shape)

print("\nSarakkeiden tietotyypit:")
print(df.dtypes.to_string())

print("\nAineiston perustiedot:")
df.info()

# Puuttuvat arvot
print("\nPuuttuvat arvot sarakkeittain:")
print(df.isna().sum().to_string())
```

```python
# Duplikaatit
print("\nTäysin identtiset rivit:")
print(df.duplicated().sum())

print("\nSaman nimiset ja saman vuoden elokuvat:")
print(df.duplicated(subset=["name", "year"]).sum())

# Tekstimuuttujien kirjoitusasut
for sarake in ["genre", "rating", "country"]:
    print(f"\n{sarake} - eri arvot:")
    print(df[sarake].value_counts(dropna=False).to_string())

# Mahdolliset virheelliset numeeriset arvot
for sarake in ["year", "score", "votes", "budget", "gross", "runtime"]:
    print(f"\n{sarake}:")
    print("Pienin:", df[sarake].min())
    print("Suurin:", df[sarake].max())
    print("Nolla-arvoja:", (df[sarake] == 0).sum())
    print("Negatiivisia arvoja:", (df[sarake] < 0).sum())
```

```
Aineiston koko: (7668, 15)

Sarakkeiden tietotyypit:
name         object
rating       object
genre        object
year          int64
released     object
score       float64
votes       float64
director     object
writer       object
star         object
country      object
budget      float64
gross       float64
company      object
runtime     float64

Aineiston perustiedot:
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 7668 entries, 0 to 7667
Data columns (total 15 columns):
 #   Column    Non-Null Count  Dtype
---  ------    --------------  -----
 0   name      7668 non-null   object
```

```
 1   rating    7591 non-null   object
 2   genre     7668 non-null   object
 3   year      7668 non-null   int64
 4   released  7666 non-null   object
 5   score     7665 non-null   float64
 6   votes     7665 non-null   float64
 7   director  7668 non-null   object
 8   writer    7665 non-null   object
 9   star      7667 non-null   object
 10  country   7665 non-null   object
 11  budget    5497 non-null   float64
 12  gross     7479 non-null   float64
 13  company   7651 non-null   object
 14  runtime   7664 non-null   float64
dtypes: float64(5), int64(1), object(9)
memory usage: 898.7+ KB

Puuttuvat arvot sarakkeittain:
name           0
rating        77
genre          0
year           0
released       2
score          3
votes          3
director       0
writer         3
star           1
country        3
budget      2171
gross        189
company       17
runtime        4

Täysin identtiset rivit:
0

Saman nimiset ja saman vuoden elokuvat:
0

genre - eri arvot:
genre
Comedy       2245
Action       1705
Drama        1518
Crime         551
Biography     443
Adventure     427
```

```
Animation     338
Horror        322
Fantasy        44
Mystery        20
Thriller       16
Family         11
Sci-Fi         10
Romance        10
Western         3
Musical         2
Music           1
History         1
Sport           1

rating - eri arvot:
rating
R            3697
PG-13        2112
PG           1252
Not Rated     283
G             153
NaN            77
Unrated        52
NC-17          23
TV-MA           9
TV-PG           5
X               3
Approved        1
TV-14           1

country - eri arvot:
country
United States                5475
United Kingdom                816
France                        279
Canada                        190
Germany                       117
Australia                      92
Japan                          81
India                          62
Italy                          61
Spain                          47
Hong Kong                      45
Ireland                        43
China                          40
South Korea                    35
Denmark                        32
New Zealand                    25
```

```
Sweden                          25
Mexico                          22
Netherlands                     12
West Germany                    12
Norway                          12
Switzerland                     10
Iran                            10
Russia                           8
Belgium                          8
Czech Republic                   8
South Africa                     8
Argentina                        8
Taiwan                           7
Thailand                         6
Hungary                          6
Brazil                           6
Israel                           5
Austria                          5
Yugoslavia                       5
Poland                           4
NaN                              3
Finland                          3
Philippines                      3
Turkey                           3
Chile                            2
Soviet Union                     2
Portugal                         2
Greece                           2
Vietnam                          2
Iceland                          2
Indonesia                        2
Federal Republic of Yugoslavia   2
United Arab Emirates             2
Libya                            1
Republic of Macedonia            1
Jamaica                          1
Aruba                            1
Serbia                           1
Colombia                         1
Romania                          1
Kenya                            1
Panama                           1
Malta                            1
Lebanon                          1

year:
Pienin: 1980
Suurin: 2020
```

```
Nolla-arvoja: 0
Negatiivisia arvoja: 0

score:
Pienin: 1.9
Suurin: 9.3
Nolla-arvoja: 0
Negatiivisia arvoja: 0

votes:
Pienin: 7.0
Suurin: 2400000.0
Nolla-arvoja: 0
Negatiivisia arvoja: 0

budget:
Pienin: 3000.0
Suurin: 356000000.0
Nolla-arvoja: 0
Negatiivisia arvoja: 0

gross:
Pienin: 309.0
Suurin: 2847246203.0
Nolla-arvoja: 0
Negatiivisia arvoja: 0

runtime:
Pienin: 55.0
Suurin: 366.0
Nolla-arvoja: 0
Negatiivisia arvoja: 0
```

Tehtävä 3: Datan puhdistaminen

Puuttuvia arvoja useissa sarakkeissa, erityisesti budjetti- ja lipputulotiedoissa. Täysin identtisiä rivejä tai selvästi virheellisiä numeerisia arvoja ei löytynyt.

Puhdistuksessa pidetään puuttuvat numeeriset tiedot puuttuvina, jotta niitä ei korvata keksityillä arvoilla. Tekstimuuttujista poistetaan mahdolliset ylimääräiset välilyönnit ja puuttuvat tekstiarvot merkitään tarvittaessa tuntemattomiksi. Lisäksi tutkitaan julkaisupäivämäärien muuntamista oikeaan tietotyyppiin.

Tekstisarakkeiden mahdolliset ylimääräiset välilyönnit poistetaan. Lisäksi rating-sarakkeen Unrated- ja Not Rated -merkinnät yhdistetään samaan luokkaan, koska ne tarkoittavat tässä tarkastelussa luokittelematonta elokuvaa.

Country-sarakkeen historialliset valtionimet, kuten Yugoslavia ja Federal Republic of Yugoslavia, säilytetään erillisinä, koska ne eivät tarkoita täysin samaa valtiota.

[3]:
```
# Luodaan puhdistettava kopio
df_clean = df_original.copy()

# Poistetaan ylimääräiset välilyönnit kaikista tekstisarakkeista
kaikki_tekstisarakkeet = df_clean.select_dtypes(
    include="object"
).columns

for sarake in kaikki_tekstisarakkeet:
    df_clean[sarake] = df_clean[sarake].str.strip()

# Puuttuvien tekstiarvojen käsittely
tekstisarakkeet = ["rating", "writer", "star", "country", "company"]

for sarake in tekstisarakkeet:
    df_clean[sarake] = df_clean[sarake].fillna("Unknown")

# Yhdistetään samaa tarkoittavat luokittelut
df_clean["rating"] = df_clean["rating"].replace(
    "Unrated", "Not Rated"
)

print("Not Rated -luokituksia puhdistuksen jälkeen:")
print((df_clean["rating"] == "Not Rated").sum())

# Erotetaan julkaisupäivämäärä tekstistä
paivamaarateksti = df_clean["released"].str.extract(
    r"^([A-Za-z]+ \d{1,2}, \d{4})"
)[0]

# Muunnetaan päivämäärä oikeaan tietotyyppiin
df_clean["release_date"] = pd.to_datetime(
    paivamaarateksti,
    format="%B %d, %Y",
    errors="coerce"
)

# Säilytetään alkuperäinen released-sarake vertailua varten
print("Puhdistetun aineiston koko:", df_clean.shape)

print("\nJulkaisupäivämäärien muunnos:")
print(df_clean[["released", "release_date"]].head(10).to_string(index=False))

print("\nPuuttuvat arvot puhdistuksen jälkeen:")
print(df_clean.isna().sum().to_string())

print("\nPäivämäärän tietotyyppi:")
```

```
print(df_clean["release_date"].dtype)
```

```
Not Rated -luokituksia puhdistuksen jälkeen:
335
Puhdistetun aineiston koko: (7668, 16)

Julkaisupäivämäärien muunnos:
                          released release_date
    June 13, 1980 (United States)   1980-06-13
     July 2, 1980 (United States)   1980-07-02
    June 20, 1980 (United States)   1980-06-20
     July 2, 1980 (United States)   1980-07-02
    July 25, 1980 (United States)   1980-07-25
      May 9, 1980 (United States)   1980-05-09
    June 20, 1980 (United States)   1980-06-20
December 19, 1980 (United States)   1980-12-19
    June 19, 1981 (United States)   1981-06-19
     May 16, 1980 (United States)   1980-05-16

Puuttuvat arvot puhdistuksen jälkeen:
name               0
rating             0
genre              0
year               0
released           2
score              3
votes              3
director           0
writer             0
star               0
country            0
budget          2171
gross            189
company            0
runtime            4
release_date      59

Päivämäärän tietotyyppi:
datetime64[ns]
```

Tehtävä 4: Puhdistetun datan vertailu alkuperäiseen

[4]:
```
vertailu = pd.DataFrame({
    "Alkuperäinen puuttuvia": df_original.isna().sum(),
    "Puhdistettu puuttuvia": (
        df_clean[df_original.columns].isna().sum()
    )
})
```

```
print("Puuttuvien arvojen vertailu:")
print(vertailu.to_string())

print("\nRivimäärä ennen:", len(df_original))
print("Rivimäärä jälkeen:", len(df_clean))

print("\nDuplikaatit puhdistuksen jälkeen:")
print(df_clean.duplicated().sum())

print("\nUuden päivämääräsarakkeen puuttuvat arvot:")
print(df_clean["release_date"].isna().sum())

print("\nSarakemäärä ennen:", df_original.shape[1])
print("Sarakemäärä jälkeen:", df_clean.shape[1])

print("\nUnrated-merkintöjä ennen:")
print((df_original["rating"] == "Unrated").sum())

print("\nUnrated-merkintöjä jälkeen:")
print((df_clean["rating"] == "Unrated").sum())
```

```
Puuttuvien arvojen vertailu:
          Alkuperäinen puuttuvia  Puhdistettu puuttuvia
name                           0                      0
rating                        77                      0
genre                          0                      0
year                           0                      0
released                       2                      2
score                          3                      3
votes                          3                      3
director                       0                      0
writer                         3                      0
star                           1                      0
country                        3                      0
budget                      2171                   2171
gross                        189                    189
company                       17                      0
runtime                        4                      4

Rivimäärä ennen: 7668
Rivimäärä jälkeen: 7668

Duplikaatit puhdistuksen jälkeen:
0

Uuden päivämääräsarakkeen puuttuvat arvot:
```

```
59

Sarakemäärä ennen: 15
Sarakemäärä jälkeen: 16

Unrated-merkintöjä ennen:
52

Unrated-merkintöjä jälkeen:
0
```

[5]:
```python
# Päivämäärät, joita ei voitu muuntaa
ongelmalliset = df_clean[
    df_clean["release_date"].isna()
    & df_clean["released"].notna()
]

print("Tunnistamattomia päivämääriä:", len(ongelmalliset))

print(
    ongelmalliset[["name", "released"]]
    .to_string(index=False)
)
```

```
Tunnistamattomia päivämääriä: 57
                                    name                        released
                                 Babylon November 1980 (United Kingdom)
                                Longshot            1981 (United States)
                       Five Days One Summer                   1982 (Japan)
                             The Personals   October 1982 (United States)
                                Nostalghia     March 1992 (United States)
                             Heat and Dust  January 1983 (United Kingdom)
                             Getting It on    August 1983 (United States)
                                Slayground  February 1984 (United States)
                     My Brother's Wedding     March 1985 (United States)
                                  Tampopo September 1987 (United States)
                          Trouble in Mind     March 1986 (United States)
                             Taipei Story                 1985 (Taiwan)
                          O.C. and Stiggs           1985 (United States)
                       The Fringe Dwellers   October 1986 (United States)
                             Duet for One  February 1987 (United States)
                                 Low Blow     April 1986 (United States)
           The House on Carroll Street            1987 (United States)
                           Five Corners      May 1988 (United Kingdom)
                          A Man in Love September 1987 (United States)
                    Drowning by Numbers      June 1991 (United States)
                              Chocolat       May 1989 (United States)
                          Stormy Monday       May 1988 (United States)
```

Pascali's Island	August 1988 (United States)
Party Line	October 1988 (United States)
Platoon Leader	October 1988 (United States)
Salome's Last Dance	June 1988 (United States)
Slaves of New York	March 1989 (United States)
Scenes from the Class Struggle in Beverly Hills	July 1989 (United States)
Monsieur Hire	June 1990 (United States)
Too Beautiful for You	April 1990 (United States)
Rosalie Goes Shopping	May 1990 (United States)
Nikita	April 1991 (United States)
The Comfort of Strangers	April 1991 (United States)
Life Is Sweet	December 1991 (United States)
The Field	March 1991 (United States)
Ju Dou	April 1991 (United States)
Hidden Agenda	January 1991 (United States)
My Father's Glory	August 1991 (United States)
Come See the Paradise	January 1991 (United States)
The Garden	1990 (United States)
May Fools	July 1990 (United States)
Strangers in Good Company	1990 (Canada)
The Nasty Girl	March 1991 (United States)
Hear My Song	February 1992 (United States)
The Pit and the Pendulum	April 1991 (United States)
The Adjuster	July 1992 (United States)
Impromptu	May 1991 (United States)
Liebestraum	November 1991 (United States)
Killing Zoe	September 1994 (United States)
Cronos	May 1994 (United States)
Bhaji on the Beach	May 1994 (United States)
Torment	November 1994 (United States)
The White Balloon	1995 (Iran)
Dahmer	2019 (United States)
Hatchet II	November 2010 (Australia)
The Human Centipede II (Full Sequence)	November 2011 (Australia)
Romeo and Juliet	2013 (United States)

Päivämäärien muunnoksessa huomasin 57 merkintää, joista puuttui tarkka julkaisupäivä. Osassa ilmoitettiin vain kuukausi ja vuosi, osassa pelkkä vuosi.

Aineistoon muodostettiin erilliset sarakkeet julkaisuvuodelle, julkaisukuukaudelle ja päivämäärän tarkkuudelle. Tarkka päivämäärä tallennetaan vain silloin, kun päivä, kuukausi ja vuosi ovat tiedossa. Puuttuvia päivätietoja ei korvata arvioiduilla arvoilla.

Ensimmäinen release_date-sarakkeen muodostaminen tehtiin päivämäärien tutkimista varten. Lopullisessa käsittelyssä sarake muodostetaan uudelleen ja aiempi versio korvataan.

Yhteensä 59 puuttuvasta tarkasta päivämäärästä 57 johtuu siitä, että alkuperäisessä tiedossa on vain kuukausi ja vuosi tai pelkkä vuosi. Kahdessa tapauksessa alkuperäinen released-arvo puuttuu kokonaan.

Lopullisessa aineistossa release_year-sarakkeesta puuttuu vain kaksi arvoa.

Tehtävän 4 vertailussa puhdistetussa aineistossa on vielä 16 saraketta. Päivämäärien tarkemman käsittelyn yhteydessä lisätään kolme uutta saraketta: release_precision, release_year ja release_month. Lopullisessa tallennetussa aineistossa on siten 19 saraketta alkuperäisen 15 sarakkeen sijaan.

[6]:
```
# Poimitaan päivämäärä ilman sulkeissa olevaa maata
paivamaarateksti = (df_clean["released"].str.replace(r"\s*\([^)]*\)\s*$", "",␣
 ↪regex=True).str.strip())

# Erotellaan päivämäärien tarkkuus
on_paiva = paivamaarateksti.str.fullmatch(r"[A-Za-z]+ \d{1,2}, \d{4}", na=False)
on_kuukausi = paivamaarateksti.str.fullmatch(r"[A-Za-z]+ \d{4}", na=False)
on_vuosi = paivamaarateksti.str.fullmatch(r"\d{4}", na=False)

df_clean["release_precision"] = "Unknown"
df_clean.loc[on_paiva, "release_precision"] = "Day"
df_clean.loc[on_kuukausi, "release_precision"] = "Month"
df_clean.loc[on_vuosi, "release_precision"] = "Year"

# Poimitaan julkaisuvuosi ja -kuukausi ilman päivän arvaamista
df_clean["release_year"] = pd.to_numeric(paivamaarateksti.str.
 ↪extract(r"(\d{4})$")[0],errors="coerce").astype("Int64")

df_clean["release_month"] = pd.to_datetime(paivamaarateksti.str.
 ↪extract(r"^([A-Za-z]+)")[0],format="%B",errors="coerce").dt.month.
 ↪astype("Int64")

# Päivämäärätyyppinen sarake vain tarkasti ilmoitetuille päiville
df_clean["release_date"] = pd.to_datetime(paivamaarateksti.
 ↪where(on_paiva),format="%B %d, %Y",errors="coerce")

print("Julkaisupäivämäärien tarkkuus:")
print(df_clean["release_precision"].value_counts())

print("\nPuuttuvat julkaisuvuodet:")
print(df_clean["release_year"].isna().sum())

print("\nEsimerkkejä käsitellyistä päivämääristä:")
print(df_clean[["released", "release_year", "release_month", "release_date",␣
 ↪"release_precision"]].head(15).to_string(index=False))
```

```
Julkaisupäivämäärien tarkkuus:
release_precision
Day        7609
Month        47
Year         10
```

```
Unknown       2
Name: count, dtype: int64

Puuttuvat julkaisuvuodet:
2

Esimerkkejä käsitellyistä päivämääristä:
                          released  release_year  release_month release_date
release_precision
     June 13, 1980 (United States)          1980              6   1980-06-13
Day
      July 2, 1980 (United States)          1980              7   1980-07-02
Day
     June 20, 1980 (United States)          1980              6   1980-06-20
Day
      July 2, 1980 (United States)          1980              7   1980-07-02
Day
     July 25, 1980 (United States)          1980              7   1980-07-25
Day
       May 9, 1980 (United States)          1980              5   1980-05-09
Day
     June 20, 1980 (United States)          1980              6   1980-06-20
Day
 December 19, 1980 (United States)          1980             12   1980-12-19
Day
     June 19, 1981 (United States)          1981              6   1981-06-19
Day
      May 16, 1980 (United States)          1980              5   1980-05-16
Day
 December 17, 1980 (United States)          1980             12   1980-12-17
Day
  October 26, 1984 (United States)          1984             10   1984-10-26
Day
 December 12, 1980 (United States)          1980             12   1980-12-12
Day
September 19, 1980 (United States)          1980              9   1980-09-19
Day
     July 25, 1980 (United States)          1980              7   1980-07-25
Day
```

Tehtävä 5: Puhdistetun aineiston tallentaminen

Puhdistettu elokuva-aineisto tallennetaan uuteen CSV-tiedostoon, jotta alkuperäinen aineisto säilyy muuttumattomana.

Puhdistuksen jälkeen aineistossa on edelleen 7 668 elokuvaa eikä duplikaatteja ole. Puuttuvat tekstiarvot on käsitelty ja julkaisupäivämäärien erilaiset tarkkuudet on huomioitu. Puuttuvat numeeriset arvot on säilytetty, koska niiden todellisia arvoja ei tunneta.

[7]:
```
# Tallennetaan puhdistettu aineisto
tiedostonimi = "movies_cleaned.csv"

df_clean.to_csv(
    tiedostonimi,
    index=False,
    encoding="utf-8-sig"
)

print("Puhdistettu aineisto tallennettu:", tiedostonimi)

# Tarkistetaan tallennetun tiedoston sisältö
df_tarkistus = pd.read_csv(tiedostonimi)

print("\nTallennetun aineiston koko:")
print(df_tarkistus.shape)

print("\nEnsimmäiset 5 riviä:")
print(df_tarkistus.head().to_string(index=False))

print("\nSarakemäärien vertailu:")
print("Sarakkeet ennen:", df_original.shape[1],
      "jälkeen:", df_clean.shape[1])
```

```
Puhdistettu aineisto tallennettu: movies_cleaned.csv

Tallennetun aineiston koko:
(7668, 19)

Ensimmäiset 5 riviä:
                                       name rating     genre  year
released  score     votes        director                 writer           star
country     budget       gross            company  runtime release_date
release_precision  release_year  release_month
                                  The Shining      R     Drama  1980 June 13,
1980 (United States)    8.4  927000.0 Stanley Kubrick            Stephen King
Jack Nicholson United Kingdom 19000000.0  46998772.0       Warner Bros.    146.0
1980-06-13               Day        1980.0            6.0
                               The Blue Lagoon      R Adventure  1980  July 2,
1980 (United States)    5.8   65000.0  Randal Kleiser Henry De Vere Stacpoole
Brooke Shields  United States  4500000.0  58853106.0  Columbia Pictures    104.0
1980-07-02               Day        1980.0            7.0
Star Wars: Episode V - The Empire Strikes Back     PG    Action  1980 June 20,
1980 (United States)    8.7 1200000.0  Irvin Kershner          Leigh Brackett
Mark Hamill  United States 18000000.0 538375067.0          Lucasfilm    124.0
1980-06-20               Day        1980.0            6.0
                                   Airplane!     PG    Comedy  1980  July 2,
```

```
1980 (United States)    7.7  221000.0    Jim Abrahams            Jim Abrahams
Robert Hays  United States  3500000.0  83453539.0 Paramount Pictures     88.0
1980-07-02               Day        1980.0            7.0
                                    Caddyshack      R    Comedy  1980 July 25,
1980 (United States)    7.3  108000.0    Harold Ramis      Brian Doyle-Murray
Chevy Chase  United States  6000000.0  39846344.0     Orion Pictures     98.0
1980-07-25               Day        1980.0            7.0

Sarakemäärien vertailu:
Sarakkeet ennen: 15 jälkeen: 19
```

Tehtävä 6: Elokuvien arvosanojen vertailu genreittäin

Viulukaavion avulla tarkastellaan elokuvien IMDb-arvosanojen jakautumista eri genreissä. Tarkasteluun valitaan kuusi yleisintä genreä, jotta kaavio pysyy selkeänä.

Kaaviosta voidaan vertailla genrejen arvosanojen vaihtelua, jakaumien muotoa ja tyypillisiä arvosanoja.

[8]:
```python
# Valitaan kuusi yleisintä genreä
yleisimmat_genret = df_clean["genre"].value_counts().head(6).index

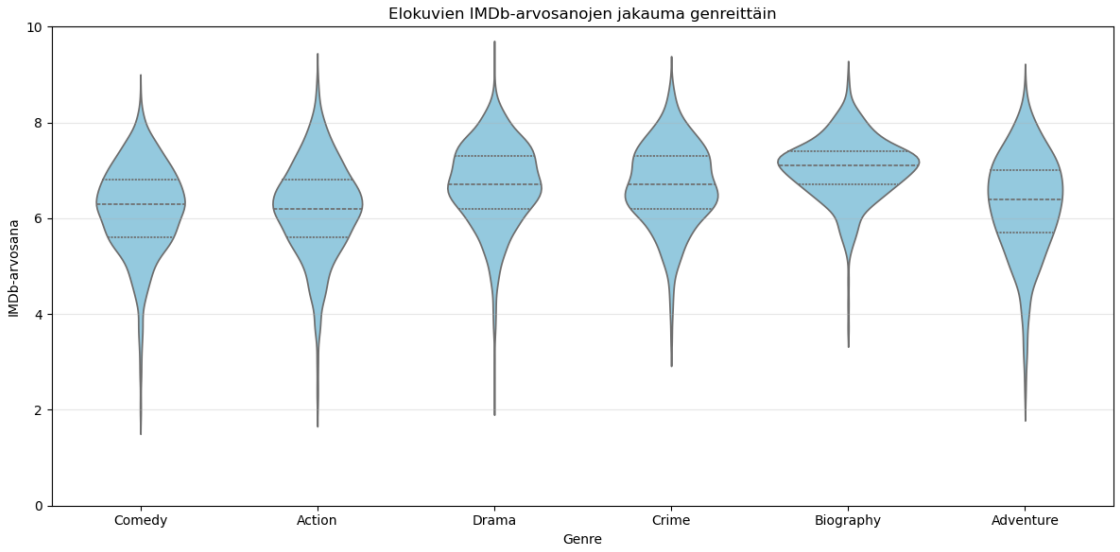
df_violin = df_clean[
    df_clean["genre"].isin(yleisimmat_genret)
].dropna(subset=["score"])

# Piirretään viulukaavio
plt.figure(figsize=(12, 6))

sns.violinplot(
    data=df_violin,
    x="genre",
    y="score",
    order=yleisimmat_genret,
    inner="quartile",
    color="skyblue"
)

plt.title("Elokuvien IMDb-arvosanojen jakauma genreittäin")
plt.xlabel("Genre")
plt.ylabel("IMDb-arvosana")
plt.ylim(0, 10)
plt.grid(axis="y", alpha=0.3)

plt.tight_layout()
plt.show()
```



Viulukaavion tulkinta

Viulukaaviosta nähdään, että Biography-elokuvien IMDb-arvosanat ovat keskimäärin korkeampia kuin muissa tarkastelluissa genreissä. Niiden mediaani on noin 7,1 ja arvosanat ovat keskittyneet melko kapealle alueelle.

Comedy- ja Adventure-elokuvissa arvosanojen vaihtelu on suurempaa ja tyypilliset arvosanat ovat Biography-elokuvia alhaisempia. Myös Drama-elokuvien arvosanat ovat suhteellisen korkeita.

Kaavio osoittaa, että arvosanojen jakaumissa on eroja eri genrejen välillä.

Tehtävä 7: Lämpökartta – elokuvien muuttujien väliset korrelaatiot

Lämpökartan avulla tarkastellaan elokuvien budjetin, lipputulojen, IMDb-arvosanojen, äänimäärien ja kestojen välisiä korrelaatioita.

Korrelaatiokertoimien avulla voidaan selvittää, mitkä muuttujat ovat yhteydessä toisiinsa. Puuttuvat arvot voidaan jättää pois kunkin muuttujaparin korrelaation laskennasta.

[9]:
```
# Valitaan numeeriset muuttujat
sarakkeet = ["budget", "gross", "score", "votes", "runtime"]

# Lasketaan korrelaatiot
korrelaatiot = df_clean[sarakkeet].corr()

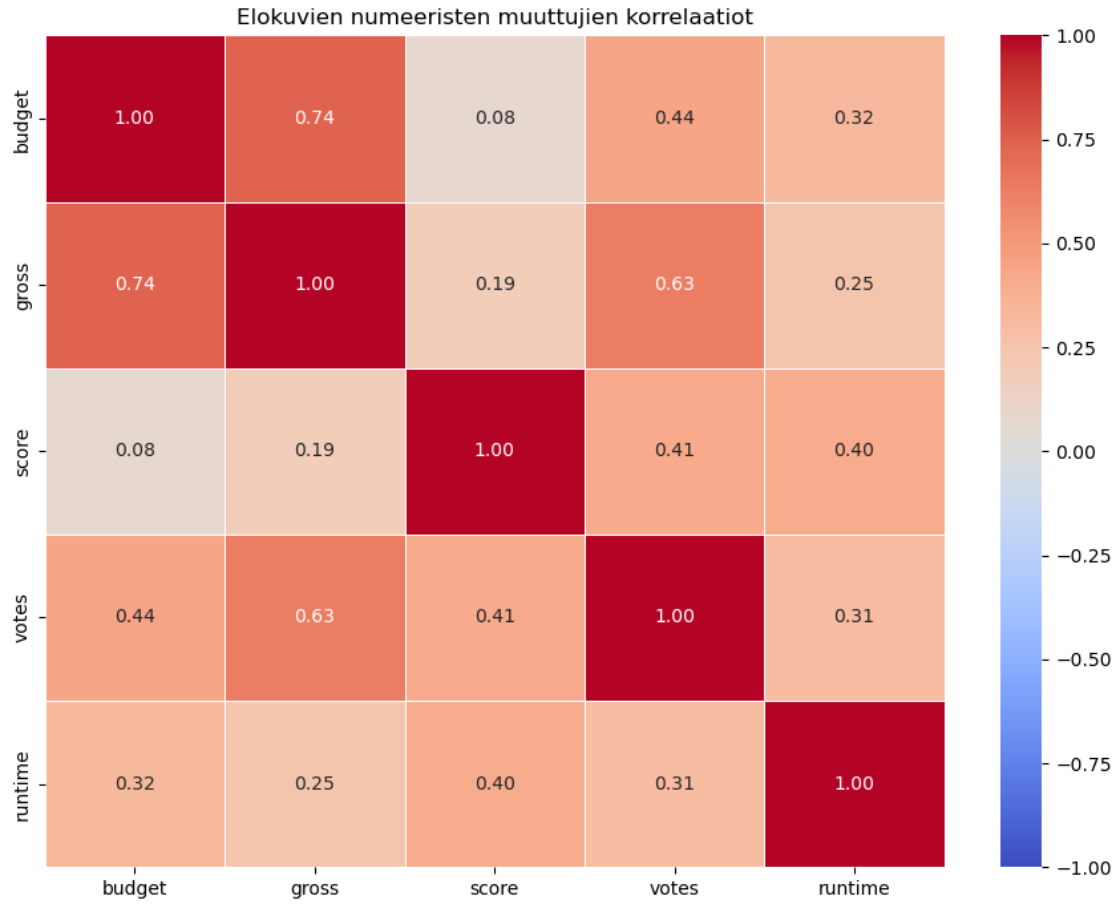
# Piirretään lämpökartta
plt.figure(figsize=(9, 7))

sns.heatmap(
    korrelaatiot,
    annot=True,
    cmap="coolwarm",
```

```
    vmin=-1,
    vmax=1,
    center=0,
    fmt=".2f",
    linewidths=0.5
)

plt.title("Elokuvien numeeristen muuttujien korrelaatiot")
plt.tight_layout()
plt.show()

# Tulostetaan korrelaatiot myös numeroina
print(korrelaatiot.round(2).to_string())
```




```
         budget  gross  score  votes  runtime
budget     1.00   0.74   0.08   0.44     0.32
gross      0.74   1.00   0.19   0.63     0.25
score      0.08   0.19   1.00   0.41     0.40
votes      0.44   0.63   0.41   1.00     0.31
```

```
runtime    0.32   0.25   0.40   0.31     1.00
```

Korrelaatioita tulkittaessa on huomioitava, että budjettitieto puuttuu 2 171 elokuvalta. Korrelaatiot on laskettu muuttujapareittain niistä havainnoista, joissa molemmat tarvittavat arvot ovat tiedossa. Tämän vuoksi esimerkiksi budjetin ja lipputulojen välinen korrelaatio ei perustu kaikkiin 7 668 elokuvaan.

Korrelaatio kuvaa muuttujien välistä lineaarista yhteyttä, mutta ei osoita syy-seuraussuhdetta.

Johtopäätökset

Tehtävässä tutkittiin ja puhdistettiin 7 668 elokuvan aineisto. Aineistossa havaittiin puuttuvia arvoja erityisesti budjetti- ja lipputulotiedoissa. Täysin identtisiä rivejä ei löytynyt.

Puhdistuksessa puuttuvat tekstiarvot korvattiin Unknown-merkinnällä ja julkaisupäivämäärien erilaiset esitysmuodot käsiteltiin. Puuttuvat numeeriset arvot säilytettiin, jotta aineistoon ei lisättäisi keksittyjä tietoja. Puhdistettu aineisto tallennettiin erilliseen CSV-tiedostoon.

Aineistosta tehtiin kaksi erilaista visualisointia: viulukaavio ja lämpökartta. Viulukaaviolla tarkasteltiin IMDb-arvosanojen jakaumia kuudessa yleisimmässä elokuvagenressä.

Lämpökartasta havaittiin, että budjetin ja lipputulojen välillä oli vahva positiivinen korrelaatio (0,74). Myös lipputulojen ja IMDb-äänimäärien välillä oli melko vahva yhteys (0,63). Sen sijaan budjetin ja IMDb-arvosanan välinen korrelaatio oli hyvin heikko (0,08).

Aineistosta ei löytynyt täysin identtisiä rivejä eikä tarkistetuista numeerisista muuttujista havaittu selvästi virheellisiä arvoja. Tekstimuuttujissa havaittiin kuitenkin epäyhtenäisiä luokittelumerkintöjä, jotka yhtenäistettiin puhdistuksen yhteydessä.