Aineistojen yhdistäminen ja sql

November 9, 2026

Northwind-aineiston analysointi

1. Tietokannan taulujen tallentaminen CSV-tiedostoiksi

Analysoidaan Northwindin myyntiaineistoa Pandasin ja SQL avulla.

Aineisto koostuu useista toisiinsa liittyvistä tietokantatauluista. Aluksi muodostetaan yhteys SQLite-tietokantaan ja tallennetaan tehtävässä tarvittavat viisi taulua erillisiksi CSV-tiedostoiksi.

Tämän jälkeen CSV-tiedostoja käytetään Pandasilla tehtävissä analyyseissä. Lopuksi samat tehtävät toteutetaan suoraan SQL-kyselyillä.

```
import pandas as pd
import sqlite3

# Muodostetaan yhteys Northwind-tietokantaan
yhteys = sqlite3.connect("/home/jovyan/shared/northwind.db")

# Määritellään vietävät taulut ja CSV-tiedostojen nimet
taulut = {
    "Customers": "customers.csv",
    "Orders": "orders.csv",
    "Order Details": "order_details.csv",
    "Products": "products.csv",
    "Categories": "categories.csv"
}

# Haetaan taulujen tiedot ja tallennetaan CSV-tiedostoiksi
for taulu, tiedosto in taulut.items():
    df = pd.read_sql_query(f'SELECT * FROM "{taulu}"', yhteys)

    df.to_csv(tiedosto, index=False, encoding="utf-8-sig")

    print(f"{taulu}: {df.shape[0]} riviä, "
          f"{df.shape[1]} saraketta -> {tiedosto}")

# Suljetaan tietokantayhteys
yhteys.close()

print("\nKaikki viisi CSV-tiedostoa tallennettu.")
```

```
Customers: 93 riviä, 11 saraketta -> customers.csv
Orders: 16282 riviä, 14 saraketta -> orders.csv
Order Details: 609283 riviä, 5 saraketta -> order_details.csv
```

```
Products: 77 riviä, 10 saraketta -> products.csv
Categories: 8 riviä, 4 saraketta ->
categories.csv Kaikki viisi CSV-tiedostoa
tallennettu.
```

Aineistoon tutustuminen

Luetaan muodostetut viisi CSV-tiedostoa Pandasin avulla. Tarkastellaan aineistojen sisältöä, kokoa, sarakkeiden nimiä ja puuttuvia arvoja.

Lisäksi selvitetään, millä tunnisteilla eri taulut liittyvät toisiinsa.

```python
import pandas as pd

# Luetaan aiemmin muodostetut CSV-tiedostot
customers = pd.read_csv("customers.csv")
orders = pd.read_csv("orders.csv")
order_details = pd.read_csv("order_details.csv")
products = pd.read_csv("products.csv")
categories = pd.read_csv("categories.csv")

# Kootaan aineistot yhteen tarkastelua varten
aineistot = {
    "Customers": customers,
    "Orders": orders,
    "Order Details": order_details,
    "Products": products,
    "Categories": categories
}

# Tutkitaan jokaisen aineiston kokoa, sarakkeita ja sisältöä
for nimi, df in aineistot.items():
    print(f"\n{'=' * 50}")
    print(f"AINEISTO: {nimi}")
    print(f"{'=' * 50}")

    print(f"Rivejä: {df.shape[0]}")
    print(f"Sarakkeita: {df.shape[1]}")

    print("\nSarakkeiden nimet:")
    print(df.columns.tolist())

    print("\nEnsimmäiset 3 riviä:")
    print(df.head(3).to_string(index=False, max_colwidth=25))

    print("\nPuuttuvat arvot sarakkeittain:")
    print(df.isna().sum().to_string())
```

```
==================================================
AINEISTO: Customers
==================================================
Rivejä: 93
Sarakkeita: 11

Sarakkeiden nimet:
['CustomerID', 'CompanyName', 'ContactName', 'ContactTitle', 'Address',
'City', 'Region', 'PostalCode', 'Country', 'Phone', 'Fax']

Ensimmäiset 3 riviä:
CustomerID           CompanyName  ContactName      ContactTitle
Address      City       Region PostalCode Country     Phone          Fax
    ALFKI     Alfreds FutterkisteMaria Anders Sales Representative
Obere Str. 57   Berlin Western Europe   12209 Germany 030-0074321
030-0076545
   ANATR Ana Trujillo Emparedad…Ana Trujillo            Owner Avda.
de la Constituci… México D.F. Central America05021 Mexico (5) 555-4729
(5) 555-3745
    ANTONAntonio Moreno Taquería Antonio Moreno           Owner
Mataderos 2312 México D.F. Central America05023 Mexico (5) 555-3932
NaN

Puuttuvat arvot sarakkeittain:
CustomerID     0
CompanyName    0
ContactName    0
ContactTitle   0
Address        2
City           2
Region         2
PostalCode     3
Country        2
Phone          2
Fax           24
==================================================
AINEISTO: Orders
==================================================
Rivejä: 16282
Sarakkeita: 14
Sarakkeiden nimet:
['OrderID', 'CustomerID', 'EmployeeID', 'OrderDate', 'RequiredDate',
'ShippedDate', 'ShipVia', 'Freight', 'ShipName', 'ShipAddress',
'ShipCity', 'ShipRegion', 'ShipPostalCode', 'ShipCountry']

Ensimmäiset 3 riviä:
```

```
 OrderID CustomerID EmployeeID OrderDate RequiredDate ShippedDate
 ShipVia
Freight               ShipName      ShipAddress     ShipCity
ShipRegion ShipPostalCode ShipCountry
  10248     VINET         5 2016-07-04 2016-08-01 2016-07-16      3
16.75 Vins et alcools Chevalier 59 rue de l-Abbaye Reims Western Europe
51100     France
  10249     TOMSP         6 2016-07-05 2016-08-16 2016-07-10      1
22.25     Toms Spezialitäten  Luisenstr. 48       Münster Western
Europe 44087        Germany
  10250     HANAR         4 2016-07-08 2016-08-05 2016-07-12      2
25.00     Hanari Carnes       Rua do Paço, 67 Rio de Janeiro South
America 05454-876   Brazil

Puuttuvat arvot sarakkeittain:
OrderID          0
CustomerID       0
EmployeeID       0
OrderDate        0
RequiredDate     0
ShippedDate     21
ShipVia          0
Freight          0
ShipName         0
ShipAddress      0
ShipCity         0
ShipRegion       0
ShipPostalCode 172
ShipCountry      0
==================================================
AINEISTO: Order Details
==================================================
Rivejä: 609283
Sarakkeita: 5

Sarakkeiden nimet:
['OrderID', 'ProductID', 'UnitPrice', 'Quantity', 'Discount']

Ensimmäiset 3 riviä:
 OrderID ProductID UnitPrice Quantity Discount
  10248        11      14.0       12      0.0
  10248        42       9.8       10      0.0
```

```
  10248        72      34.8        5      0.0

Puuttuvat arvot sarakkeittain:
OrderID    0
ProductID  0
UnitPrice  0
Quantity   0
Discount   0
==================================================
AINEISTO: Products
==================================================
Rivejä: 77
Sarakkeita: 10

Sarakkeiden nimet:
['ProductID', 'ProductName', 'SupplierID', 'CategoryID',
'QuantityPerUnit', 'UnitPrice', 'UnitsInStock', 'UnitsOnOrder',
'ReorderLevel', 'Discontinued']

Ensimmäiset 3 riviä:
 ProductIDProductName SupplierID CategoryID      QuantityPerUnit
UnitPrice UnitsInStock UnitsOnOrder ReorderLevel Discontinued
         1         Chai          1          1 10 boxes x 20 bags     18.0
39           0          10           0
         2        Chang          1          1 24 - 12 oz bottles     19.0
17          40          25           0
        3 Aniseed Syrup          1          2 12 - 550 ml bottles    10.0
13          70          25           0

Puuttuvat arvot sarakkeittain:
ProductID       0
ProductName     0
SupplierID      0
CategoryID      0
QuantityPerUnit 0
UnitPrice       0
UnitsInStock    0
UnitsOnOrder    0
ReorderLevel    0
Discontinued    0
==================================================
AINEISTO: Categories
==================================================
Rivejä: 8
Sarakkeita: 4
Sarakkeiden nimet:
```

```
['CategoryID', 'CategoryName', 'Description', 'Picture']

Ensimmäiset 3 riviä:
CategoryID CategoryName          Description                Picture
     1    Beverages Soft drinks, coffees, … b'\xff\xd8\xff\xe0\x00…
     2    Condiments Sweet and savory sauce… b'\xff\xd8\xff\xe0\x00…
     3   Confections Desserts, candies, and… b'\xff\xd8\xff\xe0\x00…

Puuttuvat arvot sarakkeittain:
CategoryID    0
CategoryName  0
Description   0
Picture       0
```

Aineiston sisältö ja rakenne

Tietokannasta muodostettiin viisi CSV-tiedostoa, jotka luettiin Pandasin avulla. Aineistojen sisältöä, sarakkeita, kokoa ja puuttuvia arvoja tarkasteltiin.

Aineistojen sisältö ja rakenne

Aineisto	Rivejä	Sarakkeita	Sisältö
Customers	93	11	Asiakkaiden yhteys- ja osoitetiedot
Orders	16 282	14	Tilaukset ja toimitustiedot
Order Details	609 283	5	Tilausrivit, hinnat, määrät ja alennukset
Products	77	10	Tuotteet, hinnat ja varastotiedot
Categories	8	4	Tuoteryhmien nimet ja kuvaukset

Taulujen väliset yhteydet

Taulut voidaan yhdistää seuraavien tunnisteiden avulla:

Customers.CustomerID = Orders.CustomerID: Yhdistää asiakkaan hänen tilauksiinsa.

Orders.OrderID = Order Details.OrderID: Yhdistää tilauksen sen sisältämiin tilausriveihin.

Order Details.ProductID = Products.ProductID: Yhdistää tilausrivin tuotteen tietoihin.

Products.CategoryID = Categories.CategoryID: Yhdistää tuotteen sen tuoteryhmään.

Näiden tunnisteiden avulla voidaan muodostaa yhtenäinen aineisto, joka sisältää asiakkaiden, tilausten, tuotteiden ja tuoteryhmien tiedot.

Puuttuvat arvot

Customers-taulussa puuttuvia arvoja esiintyy erityisesti Fax-sarakkeessa (24 puuttuvaa arvoa). Myös osoite- ja yhteystiedoissa on yksittäisiä puuttuvia arvoja.

Orders-taulussa ShippedDate-sarakkeesta puuttuu 21 arvoa ja ShipPostalCode-sarakkeesta 172 arvoa.

Order Details-, Products- ja Categories-tauluissa ei havaittu puuttuvia arvoja.

Puuttuvat arvot liittyvät pääasiassa asiakkaiden yhteystietoihin ja tilausten toimitustietoihin. Myynnin laskennassa tarvittavissa Order Details -taulun sarakkeissa ei ole puuttuvia arvoja.

2. Asiakkaat ja tilaukset

Yhdistetään asiakkaiden tiedot ja tilaukset CustomerID-tunnisteen avulla.

Tavoitteena on muodostaa aineisto, josta nähdään asiakkaan tunniste, yrityksen nimi, maa, tilauksen tunniste ja tilauspäivä. Lopuksi tarkistetaan yhdistetyn aineiston koko ja puuttuvat arvot.

```
# Yhdistetään asiakkaat ja tilaukset CustomerID-tunnisteella
asiakkaat_tilaukset = pd.merge(
    orders,
    customers,
    on="CustomerID",
    how="left",
    validate="many_to_one"
)

# Valitaan tehtävässä tarvittavat sarakkeet
asiakkaat_tilaukset = asiakkaat_tilaukset[
    ["CustomerID", "CompanyName", "Country",
     "OrderID", "OrderDate"]
]

# Näytetään ensimmäiset 10 riviä
print("Yhdistetyn aineiston ensimmäiset 10 riviä: ")
print(asiakkaat_tilaukset.head(10).to_string(index=False))

# Tarkistetaan koko
print("\nAineiston koko:")
print(asiakkaat_tilaukset.shape)

# Tarkistetaan puuttuvat arvot
print("\nPuuttuvat arvot:")
print(asiakkaat_tilaukset.isna().sum())

# Tarkistetaan, löytyykö jokaiselle tilaukselle asiakas
print("\nTilaukset, joilta puuttuu asiakkaan nimi: ")
print(asiakkaat_tilaukset["CompanyName"].isna().sum())
```

```
Yhdistetyn aineiston ensimmäiset 10 riviä:
CustomerID           CompanyName   Country OrderID OrderDate
  VINET Vins et alcools Chevalier    France   10248 2016-07-04
   TOMSP      Toms Spezialitäten    Germany  10249 2016-07-05
```

```
    HANAR          Hanari Carnes    Brazil  10250 2016-07-08
    VICTE    Victuailles en stock    France  10251 2016-07-08
    SUPRD       Suprêmes délices   Belgium  10252 2016-07-09
    HANAR          Hanari Carnes    Brazil  10253 2016-07-10
    CHOPS     Chop-suey Chinese Switzerland 10254 2016-07-11
    RICSU    Richter Supermarkt Switzerland 10255 2016-07-12
    WELLI  Wellington Importadora    Brazil  10256 2016-07-15
    HILAA       HILARION-Abastos Venezuela  10257 2016-07-16
Aineiston koko:
(16282, 5) Puuttuvat arvot:
CustomerID     0
CompanyName    0
Country 335
OrderID        0
OrderDate      0
dtype: int64
Tilaukset, joilta puuttuu asiakkaan nimi:
0
```

```python
# Selvitetään asiakkaat, joilta puuttuu maatieto
puuttuvat_asiakkaat = customers[
    customers["Country"].isna()
]

print("Asiakkaat, joilta puuttuu maatieto:")
print(
    puuttuvat_asiakkaat[
        ["CustomerID", "CompanyName", "Country"]
    ].to_string(index=False)
)

# Lasketaan näiden asiakkaiden tilaukset
puuttuvat_tilaukset = (
    asiakkaat_tilaukset[
        asiakkaat_tilaukset["Country"].isna()
    ]
    .groupby(["CustomerID", "CompanyName"])
    .agg(Tilauksia=("OrderID", "nunique"))
    .reset_index()
```

```
)

print("\nPuuttuvien maatietojen tilausmäärät:")
print(puuttuvat_tilaukset.to_string(index=False))

print("\nTilauksia yhteensä:")
print(puuttuvat_tilaukset["Tilauksia"].sum())
```

```
Asiakkaat, joilta puuttuu maatieto:
CustomerID CompanyName Country
    Val2          IT    NaN
    VALON         IT    NaN

Puuttuvien maatietojen tilausmäärät:
CustomerID CompanyName Tilauksia
    VALON         IT       176
    Val2          IT       159

Tilauksia yhteensä:
335
```

Tulosten tarkastelu

Customers- ja Orders-taulut yhdistettiin CustomerID-tunnisteen avulla käyttäen vasenta liitosta (left join).

Yhdistetty aineisto sisältää **16 282 riviä ja 5 saraketta.** Rivimäärä vastaa alkuperäisen Orderstaulun rivimäärää, joten kaikki tilaukset säilyivät yhdistämisessä.

Jokaiselle tilaukselle löytyi asiakkaan yrityksen nimi. CustomerID-, CompanyName-, OrderID- ja OrderDate-sarakkeissa ei havaittu puuttuvia arvoja.

Country-sarakkeessa oli **335 puuttuvaa arvoa.** Puuttuvat maatiedot ovat peräisin asiakasaineistosta.

Yhdistäminen onnistui, ja muodostettua aineistoa voidaan käyttää seuraavassa tehtävässä tilausten sisällön tarkasteluun.

Puuttuvien maatietojen syytä tutkittiin tarkemmin. Customers-taulussa Country-sarakkeen arvo puuttui kahdelta asiakkaalta: VALON ja Val2. Molempien yrityksen nimi oli IT.

Asiakkaalla VALON oli 176 tilausta ja asiakkaalla Val2 oli 159 tilausta. Näistä muodostui yhteensä 335 tilausta, joilta puuttui maatieto yhdistetyssä aineistossa.

Samat puuttuvat asiakastiedot näkyvät myös laajemmassa myyntiaineistossa, jossa maatieto puuttuu 13 283 tilausriviltä.

Maatietoja ei täydennetty tässä analyysissä, mutta tarvittaessa niiden täydentämistä voisi selvittää Orders-taulun ShipCountry-sarakkeen avulla. Toimitusmaa ei kuitenkaan välttämättä vastaa asiakkaan kotimaata.

3. Tilausten sisältö

Täydennetään edellisessä tehtävässä muodostettua aineistoa tilausrivien ja tuotteiden tiedoilla.

Aineistot yhdistetään OrderID- ja ProductID-tunnisteiden avulla.

Jokaiselle tilausriville lasketaan myynnin arvo kertomalla yksikköhinta tilatulla määrällä ja huomioimalla mahdollinen alennus.

Lopuksi tarkistetaan aineiston koko ja puuttuvat arvot.

```
# Yhdistetään tilaukset ja tilausrivit
myynti = pd.merge(
    asiakkaat_tilaukset,
    order_details,
    on="OrderID",
    how="inner",
    validate="one_to_many"
)

# Lisätään tuotteiden nimet ProductID-tunnisteella
myynti = pd.merge(
    myynti,
    products[["ProductID", "ProductName"]],
    on="ProductID",
    how="left",
    validate="many_to_one"
)

# Lasketaan tilausrivikohtainen myynti alennuksen jälkeen
myynti["Myynti"] = (
    myynti["UnitPrice"]
    * myynti["Quantity"]
    * (1 - myynti["Discount"])
)

# Valitaan tarkasteltavat sarakkeet
myynti = myynti[
    ["CustomerID", "CompanyName", "Country",
     "OrderID", "ProductID", "ProductName",
     "UnitPrice", "Quantity", "Discount", "Myynti"]
]

# Näytetään ensimmäiset 10 tilausriviä
print("Ensimmäiset 10 tilausriviä:")
print(myynti.head(10).to_string(index=False))

# Tarkistetaan aineiston koko
print("\nAineiston koko:")
```

```
print(myynti.shape)

# Tarkistetaan puuttuvat arvot
print("\nPuuttuvat arvot:")
print(myynti.isna().sum())

# Lasketaan myynnin kokonaisarvo
print("\nMyynnin kokonaisarvo:")
print(f"{myynti['Myynti'].sum():,.2f}")
```

```
Ensimmäiset 10 tilausriviä:
CustomerID          CompanyName Country OrderID ProductID
ProductName UnitPrice Quantity Discount Myynti
  VINET Vins et alcools Chevalier France 10248        11
Queso Cabrales    14.0       12     0.00 168.00
  VINET Vins et alcools Chevalier France 10248        42   Singaporean
Hokkien Fried Mee     9.8       10     0.00  98.00
    VINET Vins et alcools Chevalier France       10248     72
Mozzarella di Giovanni        34.8      5         0.00 174.00
    TOMSP     Toms Spezialitäten Germany  10249        14
Tofu     18.6        9     0.00 167.40
    TOMSP Toms Spezialitäten Germany 10249 Manjimup 51
Dried Apples 42.4 40 0.00 1696.00
    HANAR Hanari Carnes Brazil 10250 England Clam  41 Jack's New
Chowder 7.7 10 0.00 77.00
    HANAR Hanari Carnes Brazil 10250 Manjimup Dried 51
Apples 42.4 35 0.15 1261.40
    HANAR Hanari Carnes Brazil 10250 Hot Pepper     65     Louisiana
Sauce 16.8 15 0.15 214.20                                  Fiery
    VICTE    Victuailles en stock France  10251        22
Gustaf's Knäckebröd    16.8        6     0.05  95.76
    VICTE Victuailles en stock France   10251         57
Ravioli Angelo      15.6      15        0.05 222.30

Aineiston koko:
(609283, 10)

Puuttuvat arvot:
CustomerID       0
CompanyName      0
Country      13283
OrderID          0
ProductID        0
ProductName      0
UnitPrice        0
Quantity         0
```

```
Discount         0
```

```
Myynti           0
dtype: int64

Myynnin kokonaisarvo:
448,386,633.17
```

Tulosten tarkastelu

Asiakkaiden ja tilausten aineisto yhdistettiin Order Details- ja Products-tauluihin OrderID- ja ProductID-tunnisteiden avulla.

Muodostettu aineisto sisältää **609 283 riviä ja 10 saraketta.** Rivimäärä vastaa alkuperäisen Order Details -taulun rivimäärää, joten kaikki tilausrivit säilyivät yhdistämisessä.

Jokaiselle tilausriville laskettiin myynnin arvo kaavalla:

Myynti = UnitPrice × Quantity × (1 − Discount)

Alennus huomioitiin laskennassa. Esimerkiksi 15 prosentin alennus pienentää myyntiarvon 85 prosenttiin alkuperäisestä.

Myynnin kokonaisarvoksi saatiin **448 386 633,17.**

Country-sarakkeessa havaittiin 13 283 puuttuvaa arvoa. Muissa sarakkeissa ei ollut puuttuvia arvoja. Erityisesti myynnin laskennassa tarvittavat tiedot olivat täydellisiä.

Aineisto soveltuu seuraavaksi asiakaskohtaisen myynnin tarkasteluun.

4. Myynti asiakkaittain

Lasketaan asiakaskohtainen myynti yhdistetystä aineistosta.

Ryhmitellään aineisto asiakkaan tunnisteen, yrityksen nimen ja maan perusteella. Lasketaan jokaiselle asiakkaalle erillisten tilausten määrä sekä myynnin kokonaisarvo.

Tulokset järjestetään myynnin kokonaisarvon mukaan suurimmasta pienimpään.

```
# Ryhmitellään myynti asiakkaittain
asiakasmyynti = (
    myynti.groupby(
        ["CustomerID", "CompanyName", "Country"],
        dropna=False
    )
    .agg(
        Tilausten_maara=("OrderID", "nunique"),
        Myynti_yhteensa=("Myynti", "sum")
    )
    .reset_index()
)

# Järjestetään asiakkaat myynnin mukaan
asiakasmyynti = asiakasmyynti.sort_values(
    "Myynti_yhteensa", ascending=False
```

```
)

# Muodostetaan tulostusta varten erillinen taulukko
top15 = asiakasmyynti.head(15).copy()

# Lyhennetään sarakenimet ja yritysnimet tulostuksessa
top15 = top15.rename(columns={
    "Tilausten_maara": "Tilauksia",
    "Myynti_yhteensa": "Myynti"
})

top15["CompanyName"] = top15["CompanyName"].str.slice(0, 25)

# Näytetään myyntiarvot kahdella desimaalilla
print("15 eniten ostanutta asiakasta:")
print(top15.to_string(
    index=False,
    columns=["CustomerID", "CompanyName",
             "Country", "Tilauksia", "Myynti"],
    formatters={"Myynti": "{:.2f}".format}
))

# Tarkistetaan asiakkaiden määrä
print("\nAsiakkaita tuloksessa:")
print(len(asiakasmyynti))

# Tarkistetaan tilausten kokonaismäärä
print("\nTilausten kokonaismäärä:")
print(asiakasmyynti["Tilausten_maara"].sum())

# Lasketaan kokonaissumma ilman välipyöristyksiä
print("\nMyynnin kokonaisarvo:")
print(f"{asiakasmyynti['Myynti_yhteensa'].sum():,.2f}")
```

```
15 eniten ostanutta asiakasta:
CustomerID            CompanyName Country Tilauksia    Myynti
     BSBEV          B's Beverages      UK       210
                                                    6154115.34
     HUNGC Hungry Coyote Import Stor  USA       198
                                                    5698023.67
     RANCH          Rancho grande Argentina      194
                                                    5559110.08
     GOURL    Gourmet Lanchonetes  Brazil       202
                                                    5552309.80
     ANATR Ana Trujillo EmparedadosMexico       195
                                                    5534356.65
```

```
    RICAR     Ricardo Adocicados  Brazil      203
                                               5524517.31
    FOLIG      Folies gourmandes  France      195
                                               5505502.85
    LETSS      Let's Stop N Shop     USA      191
                                               5462198.02
    LILAS     LILA-Supermercado Venezuela     203
                                               5437438.34
    PRINI  Princesa Isabel Vinhos Portugal     200
                                               5436770.55
    BOLID Bólido Comidas preparadasSpain       182
                                               5398064.44
    PICCO        Piccolo und mehr Austria      177
                                               5366426.27
    MORGK   Morgenstern           Germany      178
            Gesundkost                         5349089.59
    WELLI   Wellington             Brazil      185
            Importadora                        5333907.69
    SPECD     Spécialités du       France      188
              monde                            5298269.65
Asiakkaita
tuloksessa: 93

Tilausten kokonaismäärä:
16282

Myynnin kokonaisarvo:
448,386,633.17
```

Tulosten tarkastelu

Myyntiaineisto ryhmiteltiin asiakkaan tunnisteen, yrityksen nimen ja maan perusteella. Jokaiselle asiakkaalle laskettiin erillisten tilausten määrä sekä myynnin kokonaisarvo alennusten jälkeen.

Tuloksessa oli **93 asiakasta ja yhteensä 16 282 tilausta**. Tilausten määrä vastaa alkuperäistä Orders-taulua.

Eniten myyntiä kertyi yritykselle **B's Beverages (UK)**, jonka myynti oli 6 154 115,34 ja tilausten määrä 210.

Seuraavaksi suurimmat asiakkaat olivat Hungry Coyote Import Store (USA) ja Rancho grande (Argentina).

Koko aineiston myynnin kokonaisarvo ilman välipyöristyksiä oli **448 386 633,17**.

Kaikki asiakkaat säilytettiin tarkastelussa, myös ne, joilta puuttui maatieto.

5. Analyysit SQL-kyselyillä

Toteutetaan tehtävät 1–4 uudelleen käyttämällä suoraan SQLite-tietokantaa ja SQL-kyselyitä.

5.1 Tietokannan rakenteen tutkiminen

Muodostetaan tietokantayhteys ja selvitetään SQL-kyselyillä tarvittavien taulujen rivimäärät, sarakkeet, esimerkkirivit ja puuttuvat arvot.

```
import sqlite3
import pandas as pd

# Muodostetaan yhteys alkuperäiseen tietokantaan
yhteys = sqlite3.connect(
    "/home/jovyan/shared/northwind.db"
)

taulut = [
    "Customers",
```

```
    "Orders",
    "Order Details",
    "Products",
    "Categories"
]

for taulu in taulut:
    print(f"\n{'=' * 50}")
    print(f"TAULU: {taulu}")
    print(f"{'=' * 50}")

    # Selvitetään rivimäärä SQL-kyselyllä
    lkm = pd.read_sql_query(
        f'SELECT COUNT(*) AS Rivimaara FROM  "{taulu}"',
        yhteys
    )

    # Selvitetään sarakkeet SQLite PRAGMA -komennolla
    sarakkeet = pd.read_sql_query(
        f'PRAGMA table_info("{taulu}")',
        yhteys
    )

    print("Rivejä:", lkm.iloc[0, 0])
    print("Sarakkeita:", len(sarakkeet))
    print("\nSarakkeiden nimet:")
    print(sarakkeet["name"].tolist())

    # Haetaan kolme esimerkkiriviä suoraan SQL:llä
    esimerkit = pd.read_sql_query(
        f'SELECT * FROM  "{taulu}" LIMIT 3',
        yhteys
    )

    print("\nEnsimmäiset 3 riviä:")
    print(esimerkit.to_string(
        index=False, max_colwidth=25
    ))
```

```
==================================================
TAULU: Customers
==================================================
Rivejä: 93
Sarakkeita: 11

Sarakkeiden nimet:
```

```
['CustomerID', 'CompanyName', 'ContactName', 'ContactTitle', 'Address',
'City', 'Region', 'PostalCode', 'Country', 'Phone', 'Fax']

Ensimmäiset 3 riviä:
CustomerID           CompanyName  ContactName      ContactTitle
Address      City       Region PostalCode Country     Phone          Fax
    ALFKI    Alfreds FutterkisteMaria Anders Sales Representative
Obere Str. 57   Berlin Western Europe   12209 Germany 030-0074321
030-0076545
   ANATR Ana Trujillo Emparedad…Ana Trujillo            Owner Avda.
de la Constituci… México D.F. Central America05021 Mexico (5) 555-4729
(5) 555-3745
    ANTONAntonio Moreno Taquería Antonio Moreno           Owner
Mataderos 2312 México D.F. Central America05023 Mexico (5) 555-3932
None

==================================================
TAULU: Orders
==================================================
Rivejä: 16282
Sarakkeita: 14

Sarakkeiden nimet:
['OrderID', 'CustomerID', 'EmployeeID', 'OrderDate', 'RequiredDate',
'ShippedDate', 'ShipVia', 'Freight', 'ShipName', 'ShipAddress',
'ShipCity', 'ShipRegion', 'ShipPostalCode', 'ShipCountry']

Ensimmäiset 3 riviä:
 OrderID CustomerID EmployeeID OrderDate RequiredDate ShippedDate
 ShipVia
Freight              ShipName      ShipAddress     ShipCity
ShipRegion ShipPostalCode ShipCountry
   10248     VINET   5 2016-07-04        2016-08-01 2016-07-16         3
16.75 Vins et alcools Chevalier 59 rue de l-Abbaye         Reims
Western Europe 51100          France
   10249     TOMSP   6 2016-07-05        2016-08-16 2016-07-10         1
22.25     Toms Spezialitäten  Luisenstr. 48       Münster Western
Europe 44087        Germany
   10250     HANAR   4 2016-07-08        2016-08-05 2016-07-12         2
25.00     Hanari Carnes       Rua do Paço, 67 Rio de Janeiro South
America 05454-876   Brazil

==================================================
TAULU: Order Details
==================================================
```

```
Rivejä: 609283
Sarakkeita: 5

Sarakkeiden nimet:
['OrderID', 'ProductID', 'UnitPrice', 'Quantity', 'Discount']

Ensimmäiset 3 riviä:
 OrderID ProductID UnitPrice Quantity Discount
   10248   11        14.0      12        0.0
   10248   42        9.8       10        0.0
   10248       72      34.8        5      0.0

==================================================
TAULU: Products
==================================================
Rivejä: 77
Sarakkeita: 10

Sarakkeiden nimet:
['ProductID', 'ProductName', 'SupplierID', 'CategoryID',
'QuantityPerUnit', 'UnitPrice', 'UnitsInStock', 'UnitsOnOrder',
'ReorderLevel', 'Discontinued']

Ensimmäiset 3 riviä:
 ProductIDProductName SupplierID CategoryID      QuantityPerUnit
UnitPrice UnitsInStock UnitsOnOrder ReorderLevel Discontinued
        1        Chai          1          1 10 boxes x 20 bags        18
39           0          10          0
        2       Chang          1          1 24 - 12 oz bottles        19
17          40          25          0
        3 Aniseed Syrup          1        2 12 - 550 ml bottles        10
13          70          25          0
==================================================
TAULU: Categories
==================================================
Rivejä: 8
Sarakkeita: 4

Sarakkeiden nimet:
['CategoryID', 'CategoryName', 'Description', 'Picture']

Ensimmäiset 3 riviä:
CategoryID CategoryName          Description                Picture
         1   Beverages Soft drinks, coffees, … b'\xff\xd8\xff\xe0\x00…
         2   Condiments Sweet and savory sauce…
             b'\xff\xd8\xff\xe0\x00…
```

```
3    Confections Desserts, candies, and…
     b'\xff\xd8\xff\xe0\x00…
```

```python
# Tarkistetaan puuttuvat arvot jokaisesta taulusta SQL:llä
for taulu in taulut:

    # Haetaan taulun sarakkeiden nimet
    sarakkeet = pd.read_sql_query(
        f'PRAGMA table_info("{taulu}")',
        yhteys
    )["name"].tolist()

    # Muodostetaan SQL-lause, joka laskee NULL-arvot
    laskennat = [
        f'SUM(CASE WHEN "{sarake}" IS NULL '
        f'THEN 1 ELSE 0 END) AS  "{sarake}"'
        for sarake in sarakkeet
    ]

    sql = (
        f'SELECT {", ".join(laskennat)} '
        f'FROM "{taulu}"'
    )

    puuttuvat = pd.read_sql_query(sql, yhteys)

    print(f"\n{taulu} - puuttuvat arvot:")
    print(puuttuvat.to_string(index=False))
```

```
Customers - puuttuvat arvot:
 CustomerID CompanyName ContactName ContactTitle Address City Region
PostalCode Country Phone Fax
          0           0           0            0       2    2      2
3       2     2   24

Orders - puuttuvat arvot:
 OrderID CustomerID EmployeeID OrderDate RequiredDate ShippedDate
 ShipVia
Freight ShipName ShipAddress ShipCity ShipRegion ShipPostalCode
ShipCountry
       0          0          0         0            0          21       0
0         0           0         0          0           172           0

Order Details - puuttuvat arvot:
 OrderID ProductID UnitPrice Quantity Discount
       0         0         0        0        0
```

```
Products – puuttuvat arvot:
 ProductID ProductName SupplierID CategoryID QuantityPerUnit UnitPrice
UnitsInStock UnitsOnOrder ReorderLevel Discontinued
         0           0           0           0               0         0
0            0            0            0

Categories – puuttuvat arvot:
 CategoryID CategoryName Description Picture
          0            0           0       0
```

SQL-tarkastelun tulokset

SQL-kyselyillä selvitettiin tietokannan viiden taulun rivimäärät, sarakkeet ja esimerkkirivit.

Tulokset vastasivat Pandasilla tehtyä tarkastelua. Tietokannassa on 93 asiakasta, 16 282 tilausta, 609 283 tilausriviä, 77 tuotetta ja 8 tuoteryhmää.

Taulut liittyvät toisiinsa CustomerID-, OrderID-, ProductID- ja CategoryID-tunnisteiden avulla.

Puuttuvia arvoja tarkastellaan SQL IS NULL -ehdolla.

5.2 Asiakkaiden ja tilausten yhdistäminen SQL:llä

Yhdistetään Customers- ja Orders-taulut CustomerID-tunnisteen avulla.

Käytetään LEFT JOIN -liitosta, jotta kaikki tilaukset säilyvät mukana. Haetaan asiakkaan tunniste, yrityksen nimi, maa, tilauksen tunniste ja tilauspäivä.

Tarkistetaan lisäksi yhdistetyn aineiston rivimäärä ja puuttuvat arvot SQL-kyselyillä.

```
# Yhdistetään tilaukset ja asiakkaat SQL-kyselyllä
sql_asiakkaat_tilaukset = """
SELECT
    o.CustomerID,
    c.CompanyName,
    c.Country,
    o.OrderID,
    o.OrderDate
FROM Orders AS o
LEFT JOIN Customers AS c
    ON o.CustomerID = c.CustomerID
"""

# Suoritetaan SQL-kysely suoraan tietokantaan
sql_tilaukset = pd.read_sql_query(
    sql_asiakkaat_tilaukset, yhteys
)

print("Yhdistetyn aineiston ensimmäiset 10 riviä: ")
print(sql_tilaukset.head(10).to_string(index=False))

# Tarkistetaan rivimäärä ja puuttuvat arvot SQL:llä
sql_tarkistus = """
SELECT
    COUNT(*) AS Rivimaara,
    SUM(CASE WHEN o.CustomerID IS NULL
        THEN 1 ELSE 0 END) AS Puuttuva_CustomerID,
    SUM(CASE WHEN c.CompanyName IS NULL
        THEN 1 ELSE 0 END) AS Puuttuva_CompanyName,
    SUM(CASE WHEN c.Country IS NULL
        THEN 1 ELSE 0 END) AS Puuttuva_Country,
    SUM(CASE WHEN o.OrderID IS NULL
        THEN 1 ELSE 0 END) AS Puuttuva_OrderID,
    SUM(CASE WHEN o.OrderDate IS NULL
        THEN 1 ELSE 0 END) AS Puuttuva_OrderDate
FROM Orders AS o
LEFT JOIN Customers AS c
    ON o.CustomerID = c.CustomerID
"""

tarkistus = pd.read_sql_query(sql_tarkistus, yhteys)

print("\nYhdistämisen tarkistus:")
print(tarkistus.to_string(index=False))
```

```
Yhdistetyn aineiston ensimmäiset 10 riviä:
```

```
CustomerID           CompanyName   Country OrderID OrderDate
  VINET Vins et alcools Chevalier   France  10248 2016-07-04
    TOMSP     Toms Spezialitäten   Germany  10249 2016-07-05
    HANAR          Hanari Carnes    Brazil  10250 2016-07-08
    VICTE   Victuailles en stock    France  10251 2016-07-08
    SUPRD       Suprêmes délices   Belgium  10252 2016-07-09
    HANAR          Hanari Carnes    Brazil  10253 2016-07-10
    CHOPS     Chop-suey Chinese Switzerland 10254 2016-07-11
    RICSU    Richter Supermarkt Switzerland 10255 2016-07-12
    WELLI  Wellington Importadora   Brazil  10256 2016-07-15
    HILAA       HILARION-Abastos Venezuela  10257 2016-07-16

Yhdistämisen tarkistus:
 Rivimaara Puuttuva_CustomerID Puuttuva_CompanyName Puuttuva_Country
Puuttuva_OrderID Puuttuva_OrderDate
    16282                 0                  0             335
0                0
```

Tulosten tarkastelu

Customers- ja Orders-taulut yhdistettiin SQL LEFT JOIN -lauseella CustomerID-tunnisteen perusteella.

Yhdistetyssä aineistossa oli **16 282 riviä**, joten kaikki tilaukset säilyivät mukana.

Jokaiselle tilaukselle löytyi asiakkaan nimi. Country-sarakkeessa havaittiin 335 puuttuvaa arvoa, mutta muissa tarkastelluissa sarakkeissa ei ollut puuttuvia arvoja.

Tulokset vastasivat täysin Pandasilla tehdyn yhdistämisen tuloksia.

5.3 Tilausten sisältö ja myynti SQL:llä

Yhdistetään asiakkaiden, tilausten, tilausrivien ja tuotteiden tiedot SQL JOIN-lauseilla.

Myynti lasketaan jokaiselle tilausriville kertomalla yksikköhinta tilatulla määrällä ja huomioimalla mahdollinen alennus.

Tarkistetaan aineiston rivimäärä, puuttuvat arvot ja myynnin kokonaisarvo. Tuloksia verrataan aiemmin Pandasilla saatuihin tuloksiin.

```
sql_myynti = """
SELECT
    o.CustomerID,
    c.CompanyName,
    c.Country,
    o.OrderID,
    od.ProductID,
    p.ProductName,
    od.UnitPrice,
    od.Quantity,
    od.Discount,
    od.UnitPrice * od.Quantity *
        (1 - od.Discount) AS Myynti
FROM Orders AS o
JOIN "Order Details" AS od
    ON o.OrderID = od.OrderID
LEFT JOIN Customers AS c
    ON o.CustomerID = c.CustomerID
LEFT JOIN Products AS p
    ON od.ProductID = p.ProductID
"""

# Haetaan ensimmäiset 10 riviä SQL-kyselyllä
sql_esimerkit = sql_myynti + " LIMIT 10"

print("Ensimmäiset 10 tilausriviä:")
print(pd.read_sql_query(
    sql_esimerkit, yhteys
).to_string(index=False))

# Tarkistetaan koko ja puuttuvat arvot SQL:llä
sql_myynti_tarkistus = """
WITH Myyntirivit AS (
""" + sql_myynti + """
)
SELECT
    COUNT(*) AS Rivimaara,
    SUM(CASE WHEN CustomerID IS NULL
# Yhdistetään neljä taulua ja lasketaan myynti SQL:llä
```

```
        THEN 1 ELSE 0 END) AS Puuttuva_CustomerID,
    SUM(CASE WHEN CompanyName IS NULL
        THEN 1 ELSE 0 END) AS Puuttuva_CompanyName,
    SUM(CASE WHEN Country IS NULL
        THEN 1 ELSE 0 END) AS Puuttuva_Country,
    SUM(CASE WHEN OrderID IS NULL
        THEN 1 ELSE 0 END) AS Puuttuva_OrderID,
    SUM(CASE WHEN ProductID IS NULL
        THEN 1 ELSE 0 END) AS Puuttuva_ProductID,
    SUM(CASE WHEN ProductName IS NULL
        THEN 1 ELSE 0 END) AS Puuttuva_ProductName,
    SUM(CASE WHEN UnitPrice IS NULL
        THEN 1 ELSE 0 END) AS Puuttuva_UnitPrice,
    SUM(CASE WHEN Quantity IS NULL
        THEN 1 ELSE 0 END) AS Puuttuva_Quantity,
    SUM(CASE WHEN Discount IS NULL
        THEN 1 ELSE 0 END) AS Puuttuva_Discount,
    SUM(CASE WHEN Myynti IS NULL
        THEN 1 ELSE 0 END) AS Puuttuva_Myynti,
    ROUND(SUM(Myynti), 2) AS Myynti_yhteensa
FROM Myyntirivit
"""

tarkistus = pd.read_sql_query(
    sql_myynti_tarkistus, yhteys
)

print("\nMyyntiaineiston tarkistus:")
print(tarkistus.to_string(index=False))
```

```
Ensimmäiset 10 tilausriviä:
CustomerID          CompanyName Country OrderID ProductID
ProductName UnitPrice Quantity Discount Myynti VINET
    Vins et alcools Chevalier France 10248 11
Queso Cabrales    14.0       12     0.00 168.00
  VINET Vins et alcools Chevalier France 10248        42   Singaporean
Hokkien Fried Mee     9.8       10     0.00  98.00
  VINET Vins et alcools Chevalier France 10248        72
Mozzarella di Giovanni   34.8        5     0.00 174.00
    TOMSP     Toms Spezialitäten Germany  10249        14
Tofu      18.6        9     0.00 167.40
    TOMSP     Toms Spezialitäten Germany  10249        51
Manjimup Dried Apples   42.4       40     0.00 1696.00
    HANAR          Hanari Carnes Brazil   10250       41 Jack's New
England Clam Chowder 7.7 10 0.00 77.00 HANAR Hanari
    Carnes Brazil 10250 51
```

```
Manjimup Dried Apples    42.4       35     0.15 1261.40
     HANAR Hanari Carnes Brazil 10250 Hot Pepper      65     Louisiana
Sauce 16.8 15 0.15 214.20                                  Fiery
    VICTE    Victuailles en stock France  10251        22
Gustaf's Knäckebröd    16.8        6     0.05  95.76
     VICTE Victuailles en stock France   10251         57
Ravioli Angelo      15.6      15        0.05 222.30
Myyntiaineiston tarkistus:
 Rivimaara Puuttuva_CustomerID Puuttuva_CompanyName Puuttuva_Country
Puuttuva_OrderID Puuttuva_ProductID Puuttuva_ProductName
Puuttuva_UnitPrice
Puuttuva_Quantity Puuttuva_Discount Puuttuva_Myynti Myynti_yhteensa
   609283                  0                   0           13283
0                 0                   0                 0
0                0              0    448386633.17
```

Tulosten tarkastelu

SQL-kyselyllä yhdistettiin Customers-, Orders-, Order Details- ja Products-taulut. Jokaiselle tilausriville laskettiin myynnin arvo huomioiden mahdollinen alennus.

Yhdistetty aineisto sisälsi **609 283 tilausriviä**, ja myynnin kokonaisarvoksi saatiin **448 386 633,17**.

Country-sarakkeessa oli 13 283 puuttuvaa arvoa. Muissa tarkastelluissa sarakkeissa ei ollut puuttuvia arvoja.

Tulokset vastasivat Pandasilla tehtyä analyysiä, joten SQL-yhdistäminen ja myyntilaskenta onnistuivat.

5.4 Myynti asiakkaittain SQL:llä

Lasketaan jokaisen asiakkaan tilausten määrä ja myynnin kokonaisarvo suoraan SQL-kyselyllä.

Taulut yhdistetään asiakkaan ja tilauksen tunnisteilla. Tilausten määrä lasketaan DISTINCTmääreellä, jotta samaa tilausta ei lasketa useita kertoja sen sisältämien tuoterivien vuoksi.

Tulokset järjestetään myynnin kokonaisarvon mukaan suurimmasta pienimpään ja niitä verrataan Pandasilla saatuihin tuloksiin.

```
sql_asiakasmyynti = """
SELECT
    c.CustomerID,
    c.CompanyName,
    c.Country,
    COUNT(DISTINCT o.OrderID) AS Tilausten_maara,
    ROUND(
        SUM(
            od.UnitPrice * od.Quantity *
            (1 - od.Discount)
        ), 2
# Lasketaan asiakaskohtainen myynti suoraan SQL:llä
```

```
    ) AS Myynti_yhteensa
FROM Customers AS c
JOIN Orders AS o
    ON c.CustomerID = o.CustomerID
JOIN "Order Details" AS od
    ON o.OrderID = od.OrderID
GROUP BY
    c.CustomerID,
    c.CompanyName,
    c.Country
ORDER BY Myynti_yhteensa DESC
"""

# Haetaan 15 eniten ostanutta asiakasta
sql_top15 = pd.read_sql_query(
    sql_asiakasmyynti + " LIMIT 15",
    yhteys
)

print("15 eniten ostanutta asiakasta SQL:llä:")
print(sql_top15.to_string(index=False))

# Tarkistetaan asiakkaiden ja tilausten kokonaismäärät
sql_yhteenveto = """
SELECT
    COUNT(DISTINCT c.CustomerID) AS Asiakkaita,
    COUNT(DISTINCT o.OrderID) AS Tilauksia,
    ROUND(
        SUM(
            od.UnitPrice * od.Quantity *
            (1 - od.Discount)
        ), 2
    ) AS Myynti_yhteensa
FROM Customers AS c
JOIN Orders AS o
    ON c.CustomerID = o.CustomerID
JOIN "Order Details" AS od
    ON o.OrderID = od.OrderID
"""

yhteenveto = pd.read_sql_query(
    sql_yhteenveto, yhteys
)

print("\nSQL-yhteenveto:")
print(yhteenveto.to_string(index=False))
```

```
15 eniten ostanutta asiakasta SQL:llä:
```

```
CustomerID                    CompanyName Country Tilausten_maara
Myynti_yhteensa
    BSBEV                   B's Beverages      UK            210
6154115.34
    HUNGC      Hungry Coyote Import Store    USA            198
5698023.67
    RANCH                  Rancho grande Argentina          194
5559110.08
    GOURL             Gourmet Lanchonetes  Brazil           202
5552309.80
  ANATR Ana Trujillo Emparedados y helados Mexico           195
5534356.65
    RICAR              Ricardo Adocicados  Brazil           203
5524517.31
    FOLIG               Folies gourmandes  France           195
5505502.85
    LETSS               Let's Stop N Shop     USA           191
5462198.02
    LILAS                LILA-Supermercado Venezuela        203
5437438.34
    PRINI           Princesa Isabel Vinhos Portugal         200
5436770.55
    BOLID        Bólido Comidas preparadas Spain            182
5398064.44
    PICCO               Piccolo und mehr Austria            177
5366426.27
    MORGK         Morgenstern Gesundkost Germany            178
5349089.59
    WELLI         Wellington Importadora  Brazil           185
5333907.69
    SPECD           Spécialités du monde  France           188
5298269.65
SQL-yhteenveto:
 Asiakkaita Tilauksia Myynti_yhteensa
         93     16282   448386633.17
```

Tulosten tarkastelu

Asiakaskohtainen myynti laskettiin SQL JOIN-, GROUP BY-, COUNT(DISTINCT)- ja SUMlausekkeilla.

Tuloksessa oli **93 asiakasta ja yhteensä 16 282 tilausta**. Myynnin kokonaisarvo alennusten jälkeen oli **448 386 633,17**.

Suurin asiakas oli **B’s Beverages (UK)**, jonka myynnin kokonaisarvo oli 6 154 115,34 ja tilausten määrä 210.

SQL-kyselyllä saatu 15 suurimman asiakkaan järjestys ja myyntiluvut vastasivat Pandasilla saatuja tuloksia.

```
import numpy as np

# Jos täytyy vielä testata
# yhteys = sqlite3.connect("/home/jovyan/shared/northwind.db")

# Suoritetaan SQL-kysely ja tallennetaan tulokset
sql_vertailu = pd.read_sql_query(
    sql_asiakasmyynti,
    yhteys
)

# Yhdistetään Pandas- ja SQL-tulokset asiakastunnuksella
vertailu = asiakasmyynti.merge(
    sql_vertailu[
        ["CustomerID", "Tilausten_maara", "Myynti_yhteensa"]
    ],
    on="CustomerID",
    how="outer",
    suffixes=("_Pandas", "_SQL"),
    indicator=True
)

# Tarkistetaan asiakasmäärät ja tilausmäärät
print("Asiakkaita Pandas:", len(asiakasmyynti))
print("Asiakkaita SQL:", len(sql_vertailu))

print("\nTilauksia Pandas:",
      asiakasmyynti["Tilausten_maara"].sum())
print("Tilauksia SQL:",
      sql_vertailu["Tilausten_maara"].sum())

# Tarkistetaan myynnin kokonaissummat
print("\nMyynti Pandas:",
      f"{asiakasmyynti['Myynti_yhteensa'].sum():.2f}")
print("Myynti SQL:",
      f"{sql_vertailu['Myynti_yhteensa'].sum():.2f}")

# Verrataan asiakaskohtaisia tilausmääriä ja myyntejä
samat_asiakkaat = vertailu["_merge"].eq("both").all()

samat_tilaukset = (
    vertailu["Tilausten_maara_Pandas"]
    .eq(vertailu["Tilausten_maara_SQL"])
    .all()
```

```
)

samat_myynnit = np.isclose(
    vertailu["Myynti_yhteensa_Pandas"],
    vertailu["Myynti_yhteensa_SQL"],
    atol=0.01,
    rtol=0
).all()

print("\nVertailun tulokset:")
print("Samat asiakkaat:", samat_asiakkaat)
print("Samat tilausmäärät:", samat_tilaukset)
print("Samat myynnit (1 sentin tarkkuudella): ",
      samat_myynnit)
```

```
Asiakkaita Pandas: 93
Asiakkaita SQL: 93

Tilauksia Pandas: 16282
Tilauksia SQL: 16282

Myynti Pandas: 448386633.17
Myynti SQL: 448386633.16

Vertailun tulokset:
Samat asiakkaat: True
Samat tilausmäärät: True
Samat myynnit (1 sentin tarkkuudella): True
```

Pandas- ja SQL-tulosten vertailu

Pandas- ja SQL-analyysien tuloksia verrattiin keskenään. Molemmilla menetelmillä saatiin 93 asiakasta ja yhteensä 16 282 tilausta.

Pandasin laskema kokonaismyynti oli 448 386 633,17 ja SQL:n 448 386 633,16. Yhden sentin ero johtuu SQL-kyselyssä tehdystä asiakaskohtaisesta pyöristyksestä.

Asiakaskohtaisten myyntisummien vertailussa kaikki tulokset vastasivat toisiaan yhden sentin tarkkuudella. Vertailu osoittaa, että molemmat menetelmät tuottivat käytännössä samat tulokset.

Yhteenveto

Northwind-aineistoa analysoitiin sekä Pandasilla että suoraan SQL-kyselyillä.

Viisi tietokantataulua vietiin ensin CSV-tiedostoiksi. Pandasilla tutkittiin aineistojen rakennetta, yhdistettiin asiakkaat ja tilaukset, laskettiin tilausrivien myyntiarvot sekä muodostettiin asiakaskohtainen myyntiyhteenveto.

Samat analyysit toteutettiin tämän jälkeen SQL-kyselyillä suoraan SQLite-tietokannasta.

Pandas- ja SQL-toteutukset antoivat samat tulokset. Aineistossa oli 93 asiakasta, 16 282 tilausta ja 609 283 tilausriviä. Myynnin kokonaisarvo oli 448 386 633,17.

```
yhteys.close()
```