Tilastollinen testaus

November 10, 2026

Tilastollinen testaus

Aineistona käytetään 150 opiskelijan tietoja sisältävää ph7.xlsx-tiedostoa. Analyysissä tutkitaan opintomenestystä, tyytyväisyyttä, liikuntaa, stressiä ja opiskelutuntien yhteyttä koepisteisiin.

Tilastollisissa testeissä käytetään merkitsevyystasoa 0,05.

1. Aineistoon tutustuminen

[1]:
```
import pandas as pd
import matplotlib.pyplot as plt
from scipy import stats

# Luetaan Excel-aineisto
df = pd.read_excel("ph7.xlsx", sheet_name="Aineisto")

# Näytetään viisi ensimmäistä riviä
print("Aineiston viisi ensimmäistä riviä:")
print(df.head())
```

```
Aineiston viisi ensimmäistä riviä:
  Opiskelija Opiskelumuoto  Koepisteet  Tyytyväisyys Liikunta Stressi  \
0      OP001          Lähi          95             2    Vähän  Matala
1      OP002          Lähi          69             5   Paljon  Matala
2      OP003          Lähi          66             4   Paljon  Matala
3      OP004          Lähi          96             5    Vähän  Matala
4      OP005          Lähi          48             4    Vähän  Matala

   Opiskelutunnit
0            10.7
1             7.1
2             8.2
3             7.5
4             2.7
```

[2]:
```
# Aineiston koko
print("Aineiston koko (rivit, sarakkeet):")
print(df.shape)
```

```
# Sarakkeiden nimet ja tietotyypit
print("\nSarakkeiden nimet ja tietotyypit:")
print(df.dtypes)

# Puuttuvat arvot
print("\nPuuttuvat arvot sarakkeittain:")
print(df.isna().sum())
```

```
Aineiston koko (rivit, sarakkeet):
(150, 7)

Sarakkeiden nimet ja tietotyypit:
Opiskelija         object
Opiskelumuoto      object
Koepisteet          int64
Tyytyväisyys        int64
Liikunta           object
Stressi            object
Opiskelutunnit    float64
dtype: object

Puuttuvat arvot sarakkeittain:
Opiskelija        0
Opiskelumuoto     0
Koepisteet        0
Tyytyväisyys      0
Liikunta          0
Stressi           0
Opiskelutunnit    0
dtype: int64
```

[3]:
```
# Numeeristen muuttujien tunnusluvut
print("Numeeristen muuttujien tunnusluvut:")
print(df[["Koepisteet", "Tyytyväisyys", "Opiskelutunnit"]].describe())

# Kategoristen muuttujien arvojen lukumäärät
for sarake in ["Opiskelumuoto", "Liikunta", "Stressi"]:
    print(f"\n{sarake} - arvojen lukumäärät:")
    print(df[sarake].value_counts())
```

```
Numeeristen muuttujien tunnusluvut:
       Koepisteet  Tyytyväisyys  Opiskelutunnit
count  150.000000    150.000000      150.000000
mean    74.320000      3.733333        8.042000
std     11.990108      1.001118        2.309922
min     48.000000      1.000000        2.000000
25%     66.000000      3.000000        6.700000
```

```
50%     74.000000      4.000000        8.200000
75%     82.000000      4.000000        9.675000
max    100.000000      5.000000       13.300000

Opiskelumuoto - arvojen lukumäärät:
Opiskelumuoto
Lähi      75
Verkko    75
Name: count, dtype: int64

Liikunta - arvojen lukumäärät:
Liikunta
Vähän     76
Paljon    74
Name: count, dtype: int64

Stressi - arvojen lukumäärät:
Stressi
Matala    76
Korkea    74
Name: count, dtype: int64
```

Aineiston kuvaus

Aineisto sisältää 150 opiskelijan tietoja opiskelumuodosta, koepisteistä, tyytyväisyydestä, liikunnan määrästä, stressitasosta ja viikoittaisista opiskelutunneista. Aineistossa on seitsemän saraketta eikä yhtään puuttuvaa arvoa.

Lähi- ja verkko-opiskelijoita on molempia 75. Vähän liikkuvia opiskelijoita on 76 ja paljon liikkuvia 74. Matalan stressitason opiskelijoita on 76 ja korkean stressitason opiskelijoita 74.

Koepisteiden keskiarvo on 74,32 ja keskihajonta 11,99 pistettä. Koepisteet vaihtelevat välillä 48–100. Tyytyväisyyden mediaani on 4 ja keskiarvo 3,73 asteikolla 1–5. Opiskeluun käytetään keskimäärin 8,04 tuntia viikossa.

Aineisto soveltuu opiskelumuotojen välisten erojen sekä liikunnan, stressin ja opintomenestyksen välisten yhteyksien tilastolliseen tarkasteluun.

2. Lähi- ja verkko-opiskelijoiden koepisteet

Tutkitaan riippumattomien otosten t-testillä, eroavatko lähi- ja verkko-opiskelijoiden koepisteiden keskiarvot.

H0: Lähi- ja verkko-opiskelijoiden koepisteiden keskiarvot ovat samat.

H1: Lähi- ja verkko-opiskelijoiden koepisteiden keskiarvot eroavat toisistaan.

Merkitsevyystaso on 0,05.

[4]:
```
# Erotellaan lähi- ja verkko-opiskelijoiden koepisteet
lahi = df.loc[df["Opiskelumuoto"] == "Lähi", "Koepisteet"]
```

```
verkko = df.loc[df["Opiskelumuoto"] == "Verkko", "Koepisteet"]

# Lasketaan ryhmien tunnusluvut
print("Lähiopiskelijat:")
print("Havaintoja:", len(lahi))
print(f"Keskiarvo: {lahi.mean():.2f}")
print(f"Keskihajonta: {lahi.std():.2f}")

print("\nVerkko-opiskelijat:")
print("Havaintoja:", len(verkko))
print(f"Keskiarvo: {verkko.mean():.2f}")
print(f"Keskihajonta: {verkko.std():.2f}")
```

```
Lähiopiskelijat:
Havaintoja: 75
Keskiarvo: 73.89
Keskihajonta: 12.81

Verkko-opiskelijat:
Havaintoja: 75
Keskiarvo: 74.75
Keskihajonta: 11.18
```

[5]:
```
# Piirretään koepisteiden laatikkokaavio
plt.figure(figsize=(7, 5))

plt.boxplot([lahi, verkko], labels=["Lähi", "Verkko"])

plt.title("Koepisteiden jakaumat opiskelumuodoittain")
plt.xlabel("Opiskelumuoto")
plt.ylabel("Koepisteet")
plt.grid(axis="y", alpha=0.3)

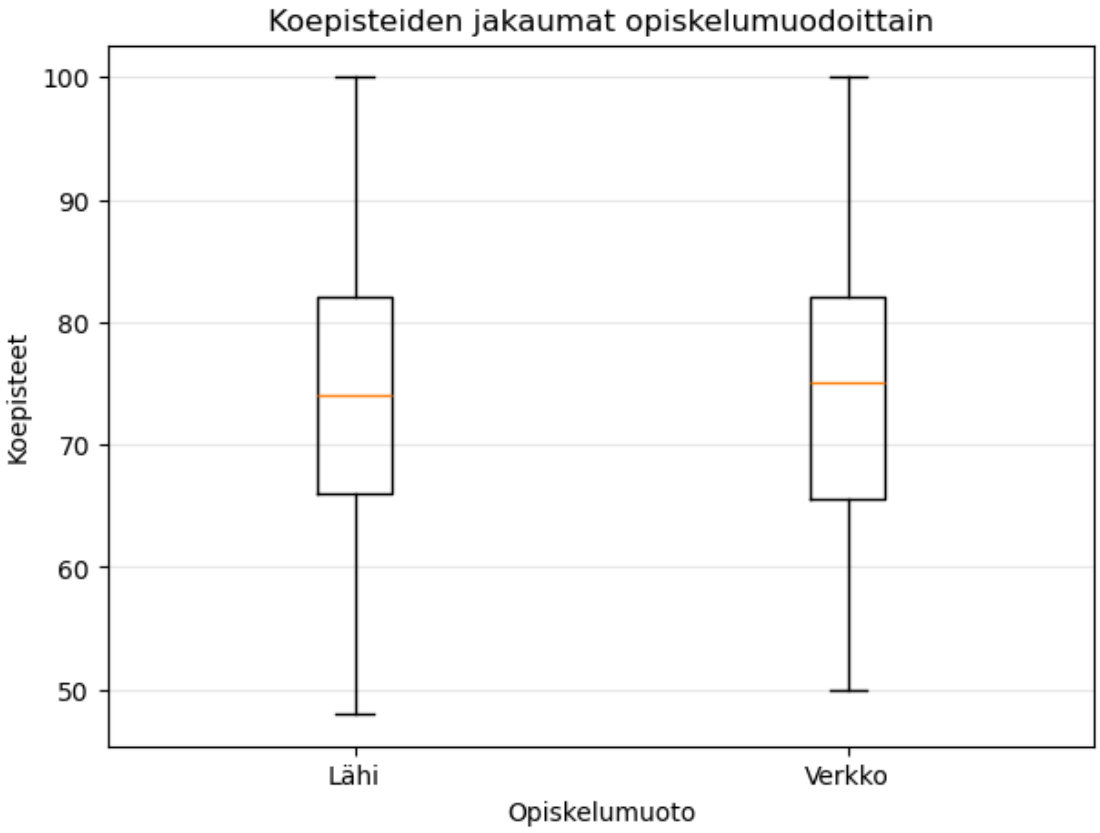
plt.show()

# Riippumattomien otosten t-testi (Welchin t-testi)
t_arvo, p_arvo = stats.ttest_ind(
    lahi,
    verkko,
    equal_var=False
)

print(f"t-testisuure: {t_arvo:.4f}")
print(f"p-arvo: {p_arvo:.4f}")

if p_arvo < 0.05:
    print("Tulos on tilastollisesti merkitsevä.")
```

```
    print("Nollahypoteesi hylätään.")
else:
    print("Tulos ei ole tilastollisesti merkitsevä.")
    print("Nollahypoteesia ei voida hylätä.")
```




```
t-testisuure: -0.4346
p-arvo: 0.6645
Tulos ei ole tilastollisesti merkitsevä.
Nollahypoteesia ei voida hylätä.
```

Tulosten tarkastelu

Lähiopiskelijoiden (n = 75) koepisteiden keskiarvo oli 73,89 ja keskihajonta 12,81. Verkko-opiskelijoiden (n = 75) keskiarvo oli 74,75 ja keskihajonta 11,18.

Verkko-opiskelijoiden keskiarvo oli noin 0,86 pistettä korkeampi kuin lähiopiskelijoiden.

Riippumattomien otosten Welchin t-testin tulokseksi saatiin $t = -0{,}4346$ ja $p = 0{,}6645$.

Koska p-arvo on suurempi kuin merkitsevyystaso 0,05, nollahypoteesia ei voida hylätä. **Lähi- ja verkko-opiskelijoiden koepisteiden keskiarvoissa ei havaittu tilastollisesti merkitsevää eroa.**

3. Lähi- ja verkko-opiskelijoiden tyytyväisyyden vertailu

Tutkitaan Mann–Whitneyn U-testillä, eroavatko lähi- ja verkko-opiskelijoiden tyytyväisyysjakaumat toisistaan.

H0: Lähi- ja verkko-opiskelijoiden tyytyväisyysjakaumat ovat samanlaiset.

H1: Lähi- ja verkko-opiskelijoiden tyytyväisyysjakaumat eroavat toisistaan.

Merkitsevyystaso on 0,05.

[6]:
```
# Erotellaan tyytyväisyysarvot opiskelumuodon perusteella
lahi_tyytyvaisyys = df.loc[
    df["Opiskelumuoto"] == "Lähi", "Tyytyväisyys"
]

verkko_tyytyvaisyys = df.loc[
    df["Opiskelumuoto"] == "Verkko", "Tyytyväisyys"
]

# Havaintomäärät ja mediaanit
print("Lähiopiskelijat:")
print("Havaintoja:", len(lahi_tyytyvaisyys))
print("Mediaani:", lahi_tyytyvaisyys.median())

print("\nVerkko-opiskelijat:")
print("Havaintoja:", len(verkko_tyytyvaisyys))
print("Mediaani:", verkko_tyytyvaisyys.median())

# Tyytyväisyysarvojen frekvenssit
print("\nLähiopiskelijoiden tyytyväisyysjakauma:")
print(lahi_tyytyvaisyys.value_counts().sort_index())

print("\nVerkko-opiskelijoiden tyytyväisyysjakauma:")
print(verkko_tyytyvaisyys.value_counts().sort_index())
```

```
Lähiopiskelijat:
Havaintoja: 75
Mediaani: 4.0

Verkko-opiskelijat:
Havaintoja: 75
Mediaani: 4.0

Lähiopiskelijoiden tyytyväisyysjakauma:
Tyytyväisyys
1     3
2     9
3    20
4    29
```

```
5    14
Name: count, dtype: int64

Verkko-opiskelijoiden tyytyväisyysjakauma:
Tyytyväisyys
2     5
3    20
4    27
5    23
Name: count, dtype: int64
```

[7]:
```python
# Mann-Whitneyn U-testi
u_arvo, p_arvo = stats.mannwhitneyu(
    lahi_tyytyvaisyys,
    verkko_tyytyvaisyys,
    alternative="two-sided"
)

print(f"U-testisuure: {u_arvo:.4f}")
print(f"p-arvo: {p_arvo:.4f}")

# Tulkitaan tulos
if p_arvo < 0.05:
    print("Tulos on tilastollisesti merkitsevä.")
    print("Nollahypoteesi hylätään.")
else:
    print("Tulos ei ole tilastollisesti merkitsevä.")
    print("Nollahypoteesia ei voida hylätä.")
```

```
U-testisuure: 2328.0000
p-arvo: 0.0569
Tulos ei ole tilastollisesti merkitsevä.
Nollahypoteesia ei voida hylätä.
```

Tulosten tarkastelu

Lähi- ja verkko-opiskelijoita oli molemmissa ryhmissä 75. Tyytyväisyyden mediaani oli kummassakin ryhmässä 4 asteikolla 1–5.

Verkko-opiskelijoista 23 antoi korkeimman tyytyväisyysarvosanan 5, kun lähiopiskelijoista sen antoi 14. Jakaumissa oli siis jonkin verran eroja, vaikka mediaanit olivat samat.

Mann–Whitneyn U-testin tulokseksi saatiin U = 2328 ja p = 0,0569.

Koska p-arvo on suurempi kuin merkitsevyystaso 0,05, nollahypoteesia ei voida hylätä. **Lähi- ja verkko-opiskelijoiden tyytyväisyydessä ei havaittu tilastollisesti merkitsevää eroa.**

Tulos oli lähellä merkitsevyysrajaa, mutta ei alittanut sitä.

4. Liikunnan ja stressin välinen yhteys

Tutkitaan chi2-riippumattomuustestillä, onko liikunnan määrällä ja koetulla stressitasolla yhteyttä.

H0: Liikunnan määrä ja stressitaso ovat toisistaan riippumattomia.

H1: Liikunnan määrällä ja stressitasolla on yhteys.

Merkitsevyystaso on 0,05.

[8]:
```
# Muodostetaan liikunnan ja stressin ristiintaulukko
ristiintaulukko = pd.crosstab(
    df["Liikunta"],
    df["Stressi"]
)

print("Liikunnan ja stressin ristiintaulukko:")
print(ristiintaulukko)

# Lasketaan myös prosenttiosuudet liikuntaryhmittäin
print("\nStressitasojen prosenttiosuudet liikuntaryhmittäin:")
print(
    pd.crosstab(
        df["Liikunta"],
        df["Stressi"],
        normalize="index"
    ).mul(100).round(1)
)
```

```
Liikunnan ja stressin ristiintaulukko:
Stressi   Korkea  Matala
Liikunta
Paljon        29      45
Vähän         45      31

Stressitasojen prosenttiosuudet liikuntaryhmittäin:
Stressi   Korkea  Matala
Liikunta
Paljon      39.2    60.8
Vähän       59.2    40.8
```

[9]:
```
# Khiin neliö -riippumattomuustesti
chi2, p_arvo, vapausasteet, odotetut = stats.chi2_contingency(
    ristiintaulukko
)

print(f"Chi2-testisuure: {chi2:.4f}")
print(f"Vapausasteet: {vapausasteet}")
print(f"p-arvo: {p_arvo:.4f}")
```

```python
# Odotetut frekvenssit
print("\nOdotetut frekvenssit:")
print(pd.DataFrame(
    odotetut,
    index=ristiintaulukko.index,
    columns=ristiintaulukko.columns
).round(2))

# Tulkinta
if p_arvo < 0.05:
    print("\nTulos on tilastollisesti merkitsevä.")
    print("Nollahypoteesi hylätään.")
else:
    print("\nTulos ei ole tilastollisesti merkitsevä.")
    print("Nollahypoteesia ei voida hylätä.")
```

```
Chi2-testisuure: 5.2385
Vapausasteet: 1
p-arvo: 0.0221

Odotetut frekvenssit:
Stressi   Korkea  Matala
Liikunta
Paljon     36.51   37.49
Vähän      37.49   38.51

Tulos on tilastollisesti merkitsevä.
Nollahypoteesi hylätään.
```

Tulosten tarkastelu

Paljon liikkuvista opiskelijoista 29 (39,2 %) koki korkeaa stressiä ja 45 (60,8 %) matalaa stressiä. Vähän liikkuvista opiskelijoista 45 (59,2 %) koki korkeaa stressiä ja 31 (40,8 %) matalaa stressiä.

Korkean stressitason osuus oli siis 20 prosenttiyksikköä suurempi vähän liikkuvien opiskelijoiden ryhmässä.

Chi2-riippumattomuustestin tulokseksi saatiin chi2 = 5,2385, vapausasteita oli 1 ja p-arvo oli 0,0221.

Koska p-arvo on pienempi kuin merkitsevyystaso 0,05, nollahypoteesi hylätään. **Liikunnan määrän ja stressitason välillä havaittiin tilastollisesti merkitsevä yhteys.**

Aineistossa paljon liikkuvilla opiskelijoilla esiintyi vähemmän korkeaa stressiä kuin vähän liikkuvilla. Tulos ei kuitenkaan osoita, että liikunnan määrä suoraan aiheuttaisi eron stressitasossa.

Khiin neliö -testissä käytettiin Yatesin jatkuvuuskorjausta, jota SciPyn chi2_contingency käyttää oletuksena 2×2 -ristiintaulukolle. Korjaus ei muuttanut tilastollista johtopäätöstä.

5. Opiskelutuntien ja koepisteiden välinen yhteys

Tutkitaan Pearsonin korrelaatiokertoimella, onko viikoittaisten opiskelutuntien ja koepisteiden välillä lineaarista yhteyttä.

H0: Opiskelutuntien ja koepisteiden välillä ei ole lineaarista korrelaatiota (rho = 0).

H1: Opiskelutuntien ja koepisteiden välillä on lineaarinen korrelaatio (rho ei ole 0).

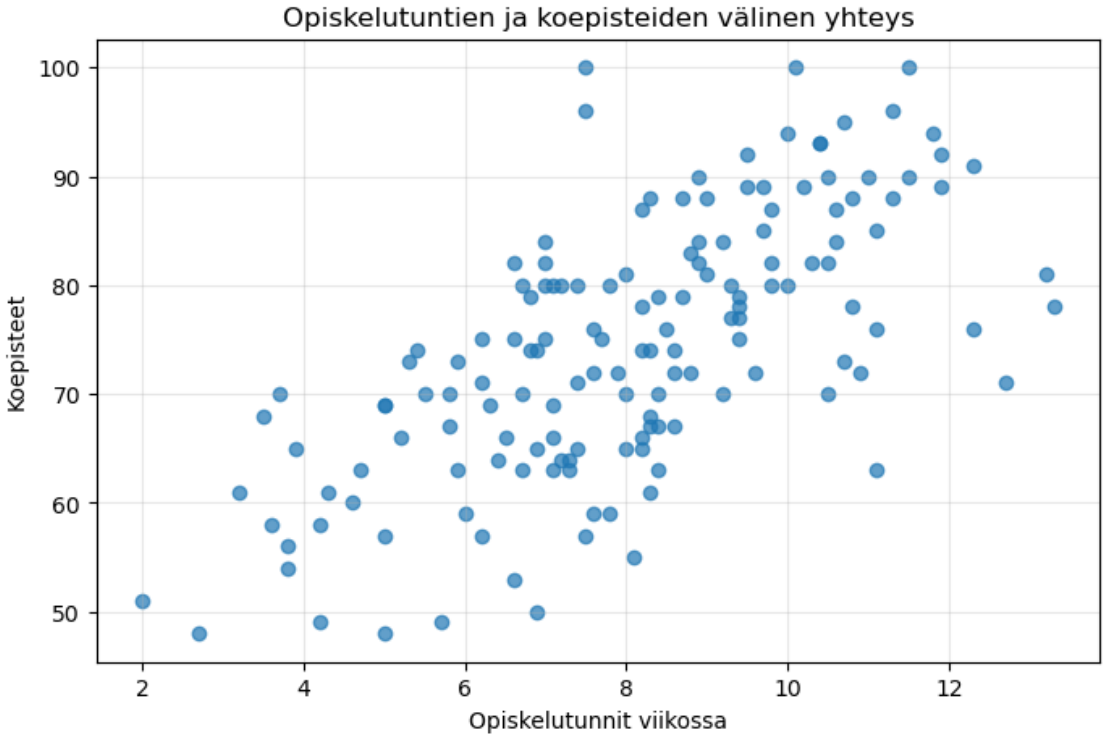
Merkitsevyystaso on 0,05.

[10]:
```
# Piirretään opiskelutuntien ja koepisteiden hajontakuvio
plt.figure(figsize=(8, 5))

plt.scatter(
    df["Opiskelutunnit"],
    df["Koepisteet"],
    alpha=0.7
)

plt.title("Opiskelutuntien ja koepisteiden välinen yhteys")
plt.xlabel("Opiskelutunnit viikossa")
plt.ylabel("Koepisteet")
plt.grid(alpha=0.3)

plt.show()
```



[11]:
```python
# Pearsonin korrelaatiokerroin ja p-arvo
r_arvo, p_arvo = stats.pearsonr(
    df["Opiskelutunnit"],
    df["Koepisteet"]
)

print(f"Pearsonin korrelaatiokerroin r: {r_arvo:.4f}")
print(f"p-arvo: {p_arvo:.6f}")

# Korrelaation suunnan ja voimakkuuden tulkinta
if r_arvo > 0:
    print("Korrelaatio on positiivinen.")
elif r_arvo < 0:
    print("Korrelaatio on negatiivinen.")
else:
    print("Korrelaatiota ei ole.")

if abs(r_arvo) < 0.3:
    print("Korrelaatio on heikko.")
elif abs(r_arvo) < 0.7:
    print("Korrelaatio on kohtalainen.")
else:
    print("Korrelaatio on voimakas.")

# Tilastollinen merkitsevyys
if p_arvo < 0.05:
    print("Tulos on tilastollisesti merkitsevä.")
    print("Nollahypoteesi hylätään.")
else:
    print("Tulos ei ole tilastollisesti merkitsevä.")
    print("Nollahypoteesia ei voida hylätä.")
```

```
Pearsonin korrelaatiokerroin r: 0.6635
p-arvo: 0.000000
Korrelaatio on positiivinen.
Korrelaatio on kohtalainen.
Tulos on tilastollisesti merkitsevä.
Nollahypoteesi hylätään.
```

Tulosten tarkastelu

Hajontakuvion perusteella opiskelutuntien ja koepisteiden välillä näyttää olevan positiivinen, voimakkuudeltaan kohtalainen yhteys. Pisteet muodostavat oikealle ylöspäin nousevan kuvion, mutta hajonta on melko laajaa. Samalla opiskelutuntimäärällä voidaan siis saada hyvinkin erilaisia koepisteitä.

Pearsonin korrelaatiokertoimeksi saatiin $r = 0{,}6635$ ja p-arvoksi $p < 0{,}001$.

Korrelaatio on positiivinen ja kohtalaisen voimakas.

Koska p-arvo on pienempi kuin merkitsevyystaso 0,05, nollahypoteesi hylätään. Opiskelutuntien ja koepisteiden välillä havaittiin tilastollisesti merkitsevä positiivinen lineaarinen yhteys.

Korrelaatio ei kuitenkaan osoita syy-seuraussuhdetta. Koepisteisiin voivat vaikuttaa opiskelutuntien lisäksi esimerkiksi opiskelijan motivaatio, aiempi osaaminen ja opiskelumenetelmät. Myös nämä tekijät voivat olla yhteydessä opiskeluun käytettyyn aikaan.

Lisäksi aineisto on tekoälyn generoimaa, joten tuloksia ei voida sellaisenaan yleistää todellisiin opiskelijoihin.