Ennustaminen ja koneoppimisen perusteet

November 13, 2026

Sähkönkulutuksen ennustaminen

Tässä tehtävässä ennustetaan Tetouanin kaupungin Zone 1 Power Consumption -sähkönkulutusta.

Aineistoon tutustutaan ensin tunnuslukujen ja visualisointien avulla. Sen jälkeen rakennetaan monimuuttujainen lineaarinen regressiomalli ja Random Forest -malli.

Mallien ennustustarkkuutta vertaillaan MAE- ja RMSE-arvojen sekä kuvaajien perusteella.

1. Aineiston lataus

[1]:
```
# %pip install ucimlrepo
```

[2]:
```
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

from ucimlrepo import fetch_ucirepo

from sklearn.linear_model import LinearRegression
from sklearn.ensemble import RandomForestRegressor
from sklearn.metrics import mean_absolute_error, mean_squared_error

sns.set_theme(style="whitegrid")

# Ladataan sähkönkulutusaineisto
data = fetch_ucirepo(id=849)

X = data.data.features
y = data.data.targets

# Yhdistetään selittävät ja ennustettavat muuttujat
df = pd.concat([X, y], axis=1)

# Näytetään viisi ensimmäistä riviä
display(df.head())
```

```
        DateTime  Temperature  Humidity  Wind Speed  general diffuse flows  \
0  1/1/2017 0:00        6.559      73.8       0.083                   0.051
```

```
1  1/1/2017 0:10        6.414      74.5       0.083                  0.070
2  1/1/2017 0:20        6.313      74.5       0.080                  0.062
3  1/1/2017 0:30        6.121      75.0       0.083                  0.091
4  1/1/2017 0:40        5.921      75.7       0.081                  0.048

   diffuse flows  Zone 1 Power Consumption  Zone 2  Power Consumption  \
0          0.119                34055.69620                16128.87538
1          0.085                29814.68354                19375.07599
2          0.100                29128.10127                19006.68693
3          0.096                28228.86076                18361.09422
4          0.085                27335.69620                17872.34043

   Zone 3  Power Consumption
0                20240.96386
1                20131.08434
2                19668.43373
3                18899.27711
4                18442.40964
```

2. Aineistoon tutustuminen

Tarkastellaan aineiston kokoa, muuttujien tietotyyppejä, puuttuvia arvoja ja numeeristen muuttujien tunnuslukuja.

Muunnetaan myös DateTime-sarake päivämäärä- ja aikatiedoksi sekä muodostetaan siitä tunti, viikonpäivä ja kuukausi.

[3]:
```
# Aineiston koko
print("Aineiston koko (rivit, sarakkeet):")
print(df.shape)

# Sarakkeiden tietotyypit
print("\nSarakkeiden tietotyypit:")
print(df.dtypes)

# Puuttuvat arvot
print("\nPuuttuvat arvot:")
print(df.isna().sum())

# Numeeristen muuttujien tunnusluvut
print("\nNumeeristen muuttujien tunnusluvut:")
display(df.describe())
```

```
Aineiston koko (rivit, sarakkeet):
(52416, 9)

Sarakkeiden tietotyypit:
DateTime                      object
Temperature                  float64
```

```
Humidity                     float64
Wind Speed                   float64
general diffuse flows        float64
diffuse flows                float64
Zone 1 Power Consumption     float64
Zone 2  Power Consumption    float64
Zone 3  Power Consumption    float64
dtype: object

Puuttuvat arvot:
DateTime                     0
Temperature                  0
Humidity                     0
Wind Speed                   0
general diffuse flows        0
diffuse flows                0
Zone 1 Power Consumption     0
Zone 2  Power Consumption    0
Zone 3  Power Consumption    0
dtype: int64

Numeeristen muuttujien tunnusluvut:

        Temperature      Humidity    Wind Speed  general diffuse flows  \
count  52416.000000  52416.000000  52416.000000           52416.000000
mean      18.810024     68.259518      1.959489             182.696614
std        5.815476     15.551177      2.348862             264.400960
min        3.247000     11.340000      0.050000               0.004000
25%       14.410000     58.310000      0.078000               0.062000
50%       18.780000     69.860000      0.086000               5.035500
75%       22.890000     81.400000      4.915000             319.600000
max       40.010000     94.800000      6.483000            1163.000000

       diffuse flows  Zone 1 Power Consumption  Zone 2  Power Consumption  \
count   52416.000000              52416.000000               52416.000000
mean       75.028022              32344.970564               21042.509082
std       124.210949               7130.562564                5201.465892
min         0.011000              13895.696200                8560.081466
25%         0.122000              26310.668692               16980.766032
50%         4.456000              32265.920340               20823.168405
75%       101.000000              37309.018185               24713.717520
max       936.000000              52204.395120               37408.860760

       Zone 3  Power Consumption
count               52416.000000
mean                17835.406218
std                  6622.165099
min                  5935.174070
```

```
25%                  13129.326630
50%                  16415.117470
75%                  21624.100420
max                  47598.326360
```

[4]:
```python
# Muunnetaan DateTime päivämäärä- ja aikatiedoksi
df["DateTime"] = pd.to_datetime(
    df["DateTime"],
    format="%m/%d/%Y %H:%M"
)

# Varmistetaan aikajärjestys
df = df.sort_values("DateTime").reset_index(drop=True)

# Muodostetaan uudet muuttujat
df["tunti"] = df["DateTime"].dt.hour
df["viikonpaiva"] = df["DateTime"].dt.dayofweek
df["kuukausi"] = df["DateTime"].dt.month

# Tarkistetaan tulos
print("Aineiston koko:", df.shape)
print("\nDateTime-sarakkeen tietotyyppi:")
print(df["DateTime"].dtype)

print("\nEnsimmäiset rivit:")
display(df[["DateTime", "tunti", "viikonpaiva", "kuukausi"]].head())

print("\nAineiston aikaväli:")
print(df["DateTime"].min())
print(df["DateTime"].max())
```

```
Aineiston koko: (52416, 12)

DateTime-sarakkeen tietotyyppi:
datetime64[ns]

Ensimmäiset rivit:
```

	DateTime	tunti	viikonpaiva	kuukausi
0	2017-01-01 00:00:00	0	6	1
1	2017-01-01 00:10:00	0	6	1
2	2017-01-01 00:20:00	0	6	1
3	2017-01-01 00:30:00	0	6	1
4	2017-01-01 00:40:00	0	6	1

```
Aineiston aikaväli:
2017-01-01 00:00:00
2017-12-30 23:50:00
```

Aineiston kuvaus

Aineisto sisältää 52 416 havaintoa Tetouanin kaupungin sähkönkulutuksesta ja sääolosuhteista vuodelta 2017. Mittaukset on tehty 10 minuutin välein aikavälillä 1.1.2017–30.12.2017.

Alkuperäisessä aineistossa on yhdeksän saraketta, eikä aineistossa ole puuttuvia arvoja.

Zone 1 -alueen sähkönkulutuksen keskiarvo on noin 32 345 ja keskihajonta noin 7 131. Kulutus vaihtelee välillä 13 896–52 204.

Lämpötilan keskiarvo on 18,81 astetta ja ilmankosteuden keskiarvo 68,26 prosenttia.

DateTime-sarake muunnettiin päivämäärä- ja aikatiedoksi. Siitä muodostettiin kolme uutta muuttujaa: tunti, viikonpäivä ja kuukausi.

Aineisto järjestettiin aikajärjestykseen myöhempää opetus- ja testiaineistoon jakamista varten.

3. Aineiston visualisointi

Sähkönkulutus ajan funktiona

Tarkastellaan Zone 1 -alueen sähkönkulutuksen vaihtelua vuoden 2017 aikana.

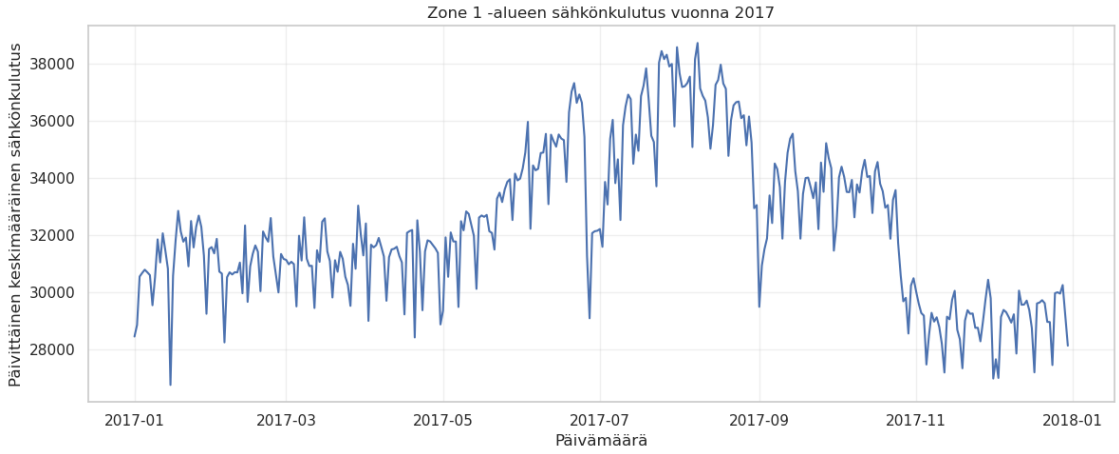
[5]:
```
# Lasketaan päivittäinen keskimääräinen sähkönkulutus
paivittainen_kulutus = (
    df.set_index("DateTime")["Zone 1 Power Consumption"]
    .resample("D")
    .mean()
)

# Piirretään kuvaaja
plt.figure(figsize=(12, 5))

plt.plot(
    paivittainen_kulutus.index,
    paivittainen_kulutus.values
)

plt.title("Zone 1 -alueen sähkönkulutus vuonna 2017")
plt.xlabel("Päivämäärä")
plt.ylabel("Päivittäinen keskimääräinen sähkönkulutus")
plt.grid(alpha=0.3)

plt.tight_layout()
plt.show()
```



Sähkönkulutuksen ajallinen vaihtelu

Kuvaajasta nähdään, että sähkönkulutus vaihtelee selvästi vuoden aikana. Kulutus kasvaa kevään jälkeen ja on korkeimmillaan heinä–elokuussa.

Syksyllä kulutus alkaa vähentyä, ja marras–joulukuussa kulutus on selvästi kesäkuukausia matalampaa.

Aineistossa näkyy siis vuodenaikaan liittyvää kausivaihtelua sekä lyhytaikaisia kulutuksen muutoksia. Koko vuoden kattavaa tasaista nousu- tai laskutrendiä ei kuitenkaan ole havaittavissa.

Koska aineisto kattaa vain yhden vuoden, pitkän aikavälin trendiä ei voida luotettavasti erottaa vuodenaikaisesta kausivaihtelusta. Useamman vuoden aineisto mahdollistaisi trendin ja toistuvan kausivaihtelun tarkemman arvioinnin.

Sähkönkulutus vuorokaudenajan mukaan

Tarkastellaan Zone 1 -alueen keskimääräistä sähkönkulutusta vuorokauden eri tunteina.

[6]:
```
# Lasketaan keskimääräinen sähkönkulutus tunneittain
tuntikulutus = df.groupby("tunti")["Zone 1 Power Consumption"].mean()

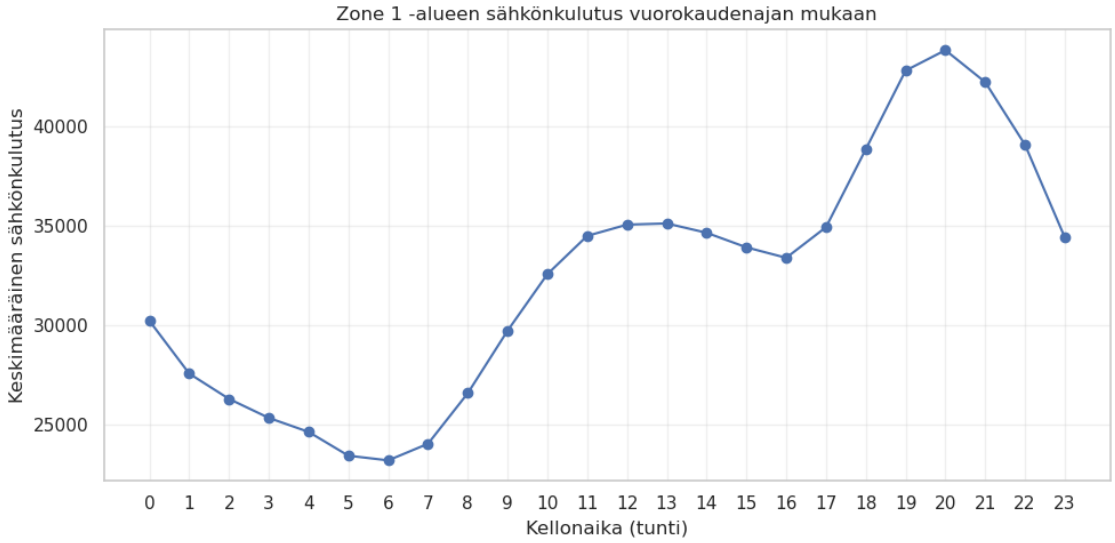
plt.figure(figsize=(10, 5))

plt.plot(
    tuntikulutus.index,
    tuntikulutus.values,
    marker="o"
)

plt.title("Zone 1 -alueen sähkönkulutus vuorokaudenajan mukaan")
plt.xlabel("Kellonaika (tunti)")
plt.ylabel("Keskimääräinen sähkönkulutus")
plt.xticks(range(0, 24))
```

```
plt.grid(alpha=0.3)

plt.tight_layout()
plt.show()
```



Sähkönkulutuksen vaihtelu vuorokauden aikana

Sähkönkulutuksessa näkyy selvä vuorokausirytmi. Kulutus on pienimmillään aamuyöllä noin klo 5–6, jolloin se on keskimäärin noin 23 000.

Aamulla kulutus alkaa kasvaa ja saavuttaa keskipäivällä noin 35 000 tason. Iltapäivällä kulutus hieman vähenee, mutta kasvaa jälleen voimakkaasti illalla.

Suurin keskimääräinen kulutus havaitaan noin klo 20, jolloin se on lähes 44 000.

Kuvaajan perusteella kellonajan ja sähkönkulutuksen välinen yhteys ei ole lineaarinen, vaan kulutuksessa esiintyy selvää vuorokausivaihtelua.

Lämpötilan ja sähkönkulutuksen välinen yhteys

Tarkastellaan hajontakuvion avulla, miten lämpötila on yhteydessä Zone 1 -alueen sähkönkulutukseen.

[7]:
```
plt.figure(figsize=(9, 5))

plt.scatter(
    df["Temperature"],
    df["Zone 1 Power Consumption"],
    alpha=0.15,
    s=8
)
```

```
plt.title("Lämpötilan ja sähkönkulutuksen välinen yhteys")
plt.xlabel("Lämpötila (°C)")
plt.ylabel("Zone 1 -alueen sähkönkulutus")
plt.grid(alpha=0.3)

plt.tight_layout()
plt.show()
```



Lämpötilan ja sähkönkulutuksen välinen yhteys

Hajontakuvion perusteella lämpötilan ja sähkönkulutuksen välillä näyttää olevan positiivinen yhteys erityisesti noin 15–30 asteen lämpötiloissa. Lämpötilan noustessa myös sähkönkulutus yleensä kasvaa.

Havainnoissa esiintyy kuitenkin huomattavaa hajontaa, ja samalla lämpötilalla voidaan havaita hyvin erilaisia sähkönkulutuslukemia.

Yhteys ei vaikuta täysin lineaariselta, vaan kuvaajassa näkyy mahdollisia epälineaarisia piirteitä. Erityisesti korkeissa lämpötiloissa sähkönkulutus ei enää kasva yhtä selvästi lämpötilan mukana.

Sähkönkulutukseen vaikuttavat todennäköisesti myös muut tekijät, kuten vuorokaudenaika ja vuodenaika. Pelkän lämpötilan perusteella sähkönkulutusta olisi siksi vaikea ennustaa tarkasti.

Ilmankosteuden ja sähkönkulutuksen välinen yhteys

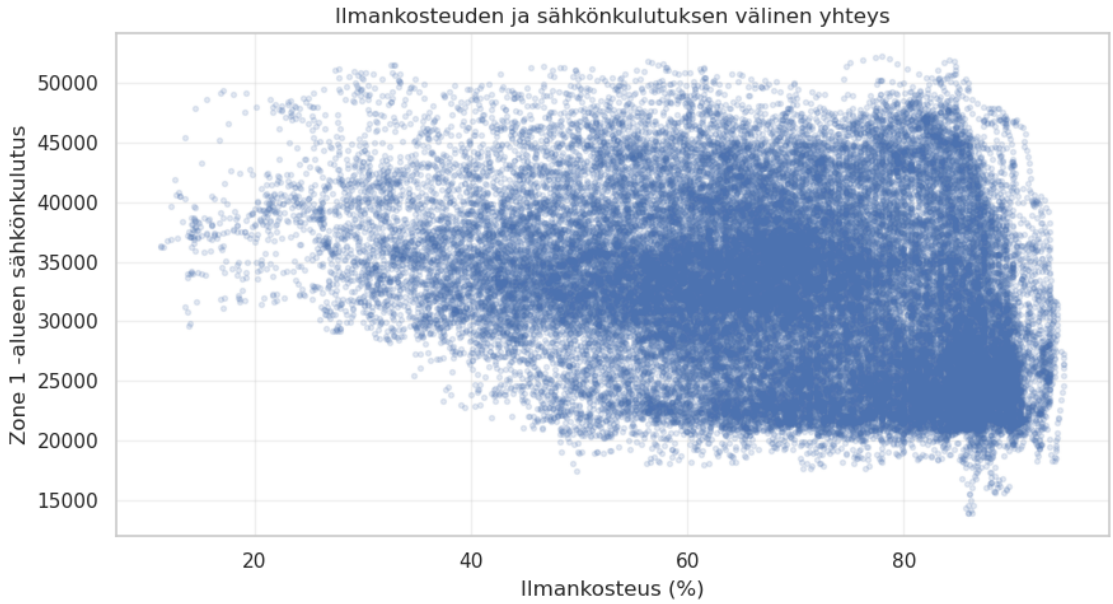
Tarkastellaan hajontakuvion avulla, miten ilmankosteus on yhteydessä Zone 1 -alueen sähkönkulutukseen.

[8]:
```
plt.figure(figsize=(9, 5))

plt.scatter(
    df["Humidity"],
    df["Zone 1 Power Consumption"],
    alpha=0.15,
    s=8
)

plt.title("Ilmankosteuden ja sähkönkulutuksen välinen yhteys")
plt.xlabel("Ilmankosteus (%)")
plt.ylabel("Zone 1 -alueen sähkönkulutus")
plt.grid(alpha=0.3)

plt.tight_layout()
plt.show()
```



Ilmankosteuden ja sähkönkulutuksen yhteys

Hajontakuvion perusteella ilmankosteuden ja sähkönkulutuksen välillä ei näy selkeää lineaarista yhteyttä.

Samalla ilmankosteudella esiintyy hyvin erilaisia sähkönkulutuslukemia, ja havaintojen hajonta on suurta.

Kuvaajassa näkyy mahdollisia epälineaarisia piirteitä, mutta pelkän ilmankosteuden perusteella sähkönkulutusta olisi vaikea ennustaa tarkasti.

Kulutukseen voivat vaikuttaa myös esimerkiksi lämpötila, vuorokaudenaika ja vuodenaika.

Sähkönkulutus viikonpäivän mukaan

Tarkastellaan Zone 1 -alueen keskimääräistä sähkönkulutusta viikon eri päivinä.

[9]:
```
# Lasketaan keskimääräinen sähkönkulutus viikonpäivittäin
viikkokulutus = df.groupby("viikonpaiva")[
    "Zone 1 Power Consumption"
].mean()

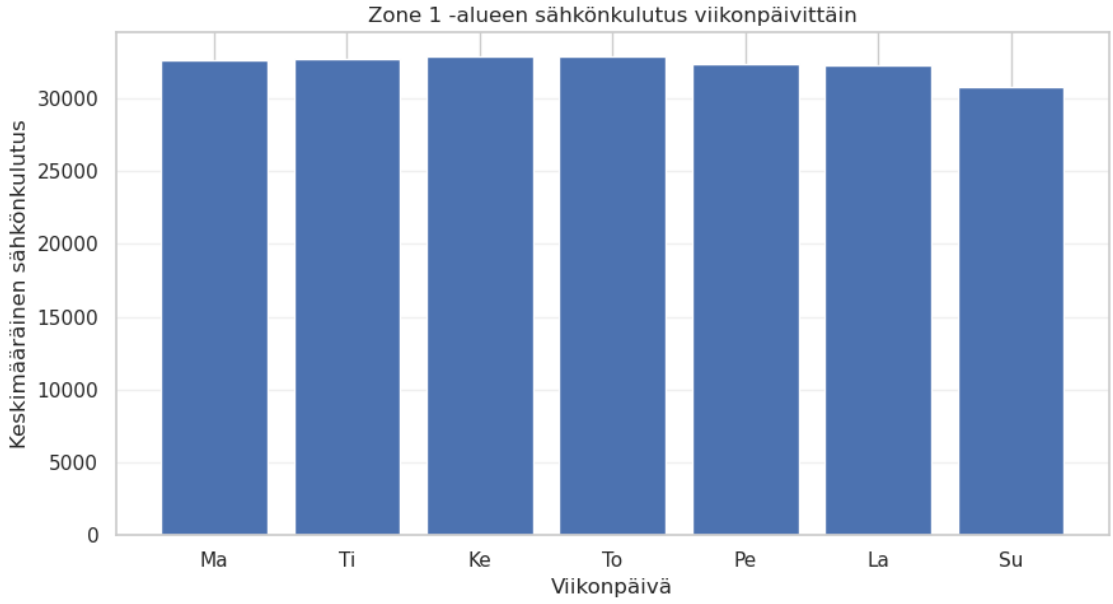
viikonpaivat = [
    "Ma", "Ti", "Ke", "To", "Pe", "La", "Su"
]

plt.figure(figsize=(9, 5))

plt.bar(
    viikonpaivat,
    viikkokulutus.values
)

plt.title("Zone 1 -alueen sähkönkulutus viikonpäivittäin")
plt.xlabel("Viikonpäivä")
plt.ylabel("Keskimääräinen sähkönkulutus")
plt.grid(axis="y", alpha=0.3)

plt.tight_layout()
plt.show()
```



Sähkönkulutuksen vaihtelu viikonpäivittäin

Sähkönkulutus on maanantaista torstaihin melko tasaista, keskimäärin noin 32 500–33 000.

Perjantaina ja lauantaina kulutus on hieman pienempää. Sunnuntaina keskimääräinen sähkönkulutus on viikon alhaisimmalla tasolla, noin 30 700.

Sunnuntain kulutus on noin 6 prosenttia pienempää kuin alkuviikon kulutus.

Kuvaajan perusteella viikonpäivien välillä esiintyy jonkin verran vaihtelua, mutta erot ovat pääosin melko pieniä.

Vaihtelu voi liittyä esimerkiksi ihmisten erilaisiin päivittäisiin rutiineihin ja sähkönkäyttötottumuksiin.

4. Aineiston jakaminen opetus- ja testiaineistoon

Ennustettavana muuttujana käytetään Zone 1 Power Consumption -sähkönkulutusta.

Selittävinä muuttujina käytetään lämpötilaa, ilmankosteutta, tuulennopeutta, kahta säteilymuuttujaa sekä tuntia, viikonpäivää ja kuukautta.

Aineisto jaetaan aikajärjestyksessä siten, että ensimmäiset 80 % havainnoista käytetään mallien opettamiseen ja viimeiset 20 % testaamiseen.

Aineistoa ei sekoiteta satunnaisesti, jotta mallit testataan ajallisesti myöhemmillä havainnoilla.

[10]:
```
# Valitaan selittävät muuttujat
muuttujat = [
    "Temperature",
    "Humidity",
    "Wind Speed",
    "general diffuse flows",
    "diffuse flows",
    "tunti",
    "viikonpaiva",
    "kuukausi"
]

X = df[muuttujat]

# Ennustettava muuttuja
y = df["Zone 1 Power Consumption"]

# Lasketaan jakokohta (80 %)
jakokohta = int(len(df) * 0.8)

# Jaetaan aineisto aikajärjestyksessä
X_train = X.iloc[:jakokohta]
X_test = X.iloc[jakokohta:]

y_train = y.iloc[:jakokohta]
```

```
y_test = y.iloc[jakokohta:]

# Tarkistetaan aineiston jako
print("Aineiston havaintojen kokonaismäärä:", len(df))
print("Jakokohta:", jakokohta)

print("\nOpetusaineisto:")
print("X_train:", X_train.shape)
print("y_train:", y_train.shape)

print("\nTestiaineisto:")
print("X_test:", X_test.shape)
print("y_test:", y_test.shape)

print("\nOpetusaineiston aikaväli:")
print(df["DateTime"].iloc[0], "-",
      df["DateTime"].iloc[jakokohta - 1])

print("\nTestiaineiston aikaväli:")
print(df["DateTime"].iloc[jakokohta], "-",
      df["DateTime"].iloc[-1])
```

```
Aineiston havaintojen kokonaismäärä: 52416
Jakokohta: 41932

Opetusaineisto:
X_train: (41932, 8)
y_train: (41932,)

Testiaineisto:
X_test: (10484, 8)
y_test: (10484,)

Opetusaineiston aikaväli:
2017-01-01 00:00:00 - 2017-10-19 04:30:00

Testiaineiston aikaväli:
2017-10-19 04:40:00 - 2017-12-30 23:50:00
```

5. Monimuuttujainen lineaarinen regressio

Muodostetaan monimuuttujainen lineaarinen regressiomalli, joka ennustaa Zone 1 -alueen sähkönkulutusta kahdeksan selittävän muuttujan perusteella.

Malli opetetaan 80 prosentin opetusaineistolla ja ennusteet tehdään 20 prosentin testiaineistolle.

Mallin ennustustarkkuutta arvioidaan MAE- ja RMSE-arvoilla. MAE kuvaa ennusteiden keskimääräistä absoluuttista virhettä. RMSE puolestaan antaa suuremmille ennustevirheille enemmän painoarvoa.

[11]:
```
import numpy as np

# Luodaan lineaarinen regressiomalli
lineaarinen_malli = LinearRegression()

# Opetetaan malli opetusaineistolla
lineaarinen_malli.fit(X_train, y_train)

# Ennustetaan testiaineiston sähkönkulutus
y_pred_linear = lineaarinen_malli.predict(X_test)

# Lasketaan ennustevirheet
mae_linear = mean_absolute_error(y_test, y_pred_linear)
rmse_linear = np.sqrt(mean_squared_error(y_test, y_pred_linear))

# Tulostetaan tulokset
print("Lineaarisen regression tulokset:")
print(f"MAE: {mae_linear:.2f}")
print(f"RMSE: {rmse_linear:.2f}")

# Näytetään viisi ensimmäistä ennustetta
vertailu_linear = pd.DataFrame({
    "Toteutunut": y_test.values,
    "Ennustettu": y_pred_linear
})

print("\nViisi ensimmäistä ennustetta:")
display(vertailu_linear.head())
```

```
Lineaarisen regression tulokset:
MAE: 3246.51
RMSE: 4075.93

Viisi ensimmäistä ennustetta:
```

	Toteutunut	Ennustettu
0	25573.39168	27308.376378
1	25686.82713	27363.487184
2	26537.59300	28076.062988
3	26928.31510	28083.847167
4	26758.16193	28100.043953

Tulosten tarkastelu

Lineaarisen regressiomallin MAE-arvoksi saatiin 3246,51 ja RMSE-arvoksi 4075,93.

MAE:n perusteella mallin ennusteet poikkeavat toteutuneesta sähkönkulutuksesta keskimäärin noin 3247 yksikköä.

RMSE on MAE-arvoa suurempi, koska se antaa suuremmille ennustevirheille enemmän painoarvoa.

Mallin tarkkuutta verrataan seuraavaksi Random Forest -malliin samalla testiaineistolla.

6. Random Forest -regressiomalli

Muodostetaan Random Forest -regressiomalli sähkönkulutuksen ennustamiseen.

Random Forest perustuu useisiin päätöspuihin ja pystyy mallintamaan myös epälineaarisia yhteyksiä.

Malli opetetaan samalla opetusaineistolla kuin lineaarinen regressio. Ennustustarkkuutta arvioidaan MAE- ja RMSE-arvoilla.

[12]:
```
# Luodaan Random Forest -malli
rf_malli = RandomForestRegressor(
    n_estimators=100,
    random_state=42,
    n_jobs=-1
)

# Opetetaan malli
rf_malli.fit(X_train, y_train)

# Ennustetaan testiaineiston sähkönkulutus
y_pred_rf = rf_malli.predict(X_test)

# Lasketaan ennustevirheet
mae_rf = mean_absolute_error(y_test, y_pred_rf)
rmse_rf = np.sqrt(mean_squared_error(y_test, y_pred_rf))

print("Random Forest -mallin tulokset:")
print(f"MAE: {mae_rf:.2f}")
print(f"RMSE: {rmse_rf:.2f}")

# Näytetään viisi ensimmäistä ennustetta
vertailu_rf = pd.DataFrame({
    "Toteutunut": y_test.values,
    "Ennustettu": y_pred_rf
})

print("\nViisi ensimmäistä ennustetta:")
display(vertailu_rf.head())
```

```
Random Forest -mallin tulokset:
MAE: 4304.93
RMSE: 4758.18

Viisi ensimmäistä ennustetta:
```

```
    Toteutunut    Ennustettu
0  25573.39168  25732.190718
1  25686.82713  25750.855141
2  26537.59300  27525.741796
3  26928.31510  27606.533041
4  26758.16193  27309.836324
```

Tulosten tarkastelu

Random Forest -mallin MAE-arvoksi saatiin 4304,93 ja RMSE-arvoksi 4758,18.

MAE:n perusteella mallin ennusteet poikkeavat toteutuneesta sähkönkulutuksesta keskimäärin noin 4305 yksikköä.

RMSE on MAE-arvoa suurempi, mikä kertoo suurempien ennustevirheiden vaikutuksesta.

Random Forest -mallin ennustevirheet ovat suurempia kuin lineaarisella regressiomallilla.

7. Mallien vertailu

Verrataan lineaarisen regression ja Random Forest -mallin ennustustarkkuutta samalla testiaineistolla.

Pienemmät MAE- ja RMSE-arvot tarkoittavat tarkempia ennusteita.

[13]:
```
# Muodostetaan mallien vertailutaulukko
mallien_vertailu = pd.DataFrame({
    "Malli": ["Lineaarinen regressio", "Random Forest"],
    "MAE": [mae_linear, mae_rf],
    "RMSE": [rmse_linear, rmse_rf]
})

display(mallien_vertailu.round(2))
```

```
                  Malli      MAE     RMSE
0  Lineaarinen regressio  3246.51  4075.93
1          Random Forest  4304.93  4758.18
```

Mallien ennustustarkkuuden vertailu

Lineaarisen regression MAE oli 3246,51 ja RMSE 4075,93.

Random Forest -mallin MAE oli 4304,93 ja RMSE 4758,18.

Lineaarinen regressio saavutti pienemmät ennustevirheet molemmilla mittareilla, joten se ennusti sähkönkulutusta tarkemmin tällä testiaineistolla.

Random Forest pystyy mallintamaan epälineaarisia yhteyksiä, mutta se ei tässä kokeessa johtanut parempaan ennustustarkkuuteen.

Toteutunut ja ennustettu sähkönkulutus

Verrataan toteutunutta sähkönkulutusta lineaarisen regression ja Random Forest -mallin ennusteisiin.

Kuvaajassa esitetään testiaineiston ensimmäinen viikko, jotta ennusteiden ja toteutuneiden arvojen erot ovat helposti havaittavissa.

[14]:
```
# Testiaineiston ensimmäinen viikko
n = 1008

# Testiaineiston päivämäärät
testiajat = df["DateTime"].iloc[jakokohta:].reset_index(drop=True)

plt.figure(figsize=(13, 5))

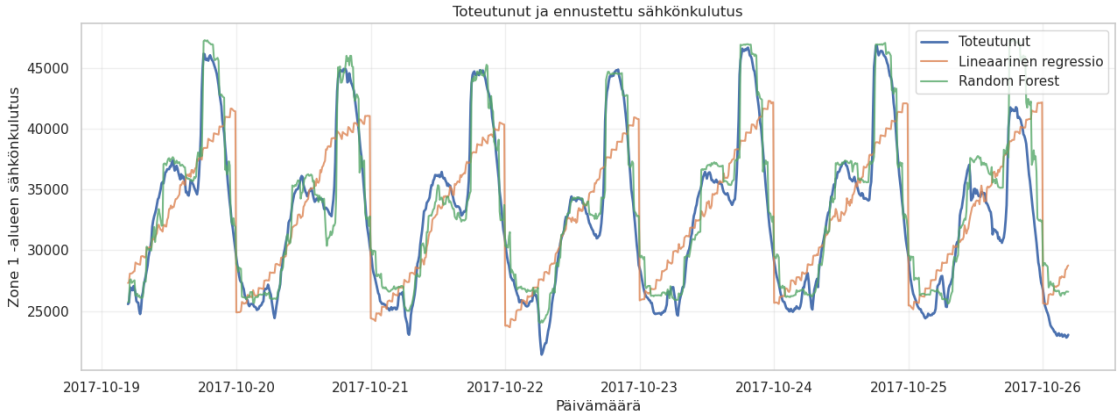
# Toteutunut sähkönkulutus
plt.plot(
    testiajat.iloc[:n],
    y_test.iloc[:n],
    label="Toteutunut",
    linewidth=2
)

# Lineaarisen regression ennuste
plt.plot(
    testiajat.iloc[:n],
    y_pred_linear[:n],
    label="Lineaarinen regressio",
    alpha=0.8
)

# Random Forest -ennuste
plt.plot(
    testiajat.iloc[:n],
    y_pred_rf[:n],
    label="Random Forest",
    alpha=0.8
)

plt.title("Toteutunut ja ennustettu sähkönkulutus")
plt.xlabel("Päivämäärä")
plt.ylabel("Zone 1 -alueen sähkönkulutus")
plt.legend()
plt.grid(alpha=0.3)

plt.tight_layout()
plt.show()
```



Toteutuneiden ja ennustettujen arvojen vertailu

Kuvaajassa näkyy selvä sähkönkulutuksen vuorokausirytmi.

Lineaarinen regressio seuraa kulutuksen yleistä vaihtelua, mutta sen ennusteet ovat tasaisempia eivätkä saavuta kaikkia toteutuneita kulutushuippuja.

Random Forest seuraa ensimmäisen testiviikon aikana kulutuksen nopeita muutoksia ja korkeita kulutushuippuja usein tarkemmin kuin lineaarinen regressio.

Kuvaaja esittää kuitenkin vain testiaineiston ensimmäisen viikon. Koko testiaineiston MAE- ja RMSE-arvojen perusteella lineaarinen regressio on kokonaisuutena tarkempi.

Toteutunut ja ennustettu sähkönkulutus joulukuussa

Tarkastellaan seuraavaksi testiaineiston viimeistä viikkoa.

Tämän kuvaajan avulla voidaan arvioida, miten mallit ennustavat sähkönkulutusta loppuvuonna ja esiintyykö ennusteissa järjestelmällistä yli- tai aliarviointia.

[15]:
```
# Testiaineiston viimeinen viikko
n = 1008

plt.figure(figsize=(13, 5))

# Toteutunut sähkönkulutus
plt.plot(
    testiajat.iloc[-n:],
    y_test.iloc[-n:],
    label="Toteutunut",
    linewidth=2
)

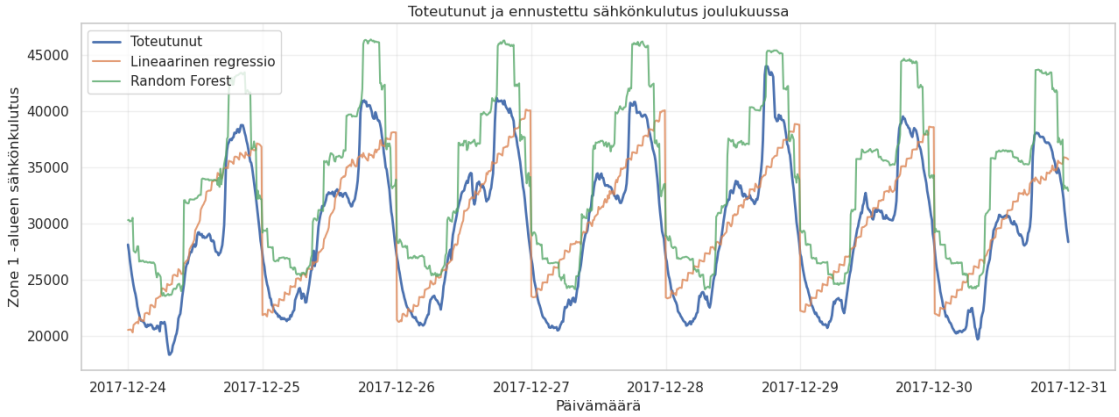
# Lineaarisen regression ennuste
plt.plot(
```

```
    testiajat.iloc[-n:],
    y_pred_linear[-n:],
    label="Lineaarinen regressio",
    alpha=0.8
)

# Random Forest -ennuste
plt.plot(
    testiajat.iloc[-n:],
    y_pred_rf[-n:],
    label="Random Forest",
    alpha=0.8
)

plt.title("Toteutunut ja ennustettu sähkönkulutus joulukuussa")
plt.xlabel("Päivämäärä")
plt.ylabel("Zone 1 -alueen sähkönkulutus")
plt.legend()
plt.grid(alpha=0.3)

plt.tight_layout()
plt.show()
```



Mallien ennustevirheiden tarkastelu

Tarkastellaan lineaarisen regression ja Random Forest -mallin residuaaleja eli toteutuneiden ja ennustettujen arvojen erotuksia.

Residuaalikuvaajan avulla voidaan arvioida, esiintyykö ennusteissa järjestelmällisiä virheitä tai ajallista vaihtelua.

[16]:
```
# Lasketaan molempien mallien residuaalit
residuaalit_linear = y_test.to_numpy() - y_pred_linear
```

```
residuaalit_rf = y_test.to_numpy() - y_pred_rf

# Piirretään residuaalit koko testiaineiston ajalta
plt.figure(figsize=(13, 5))

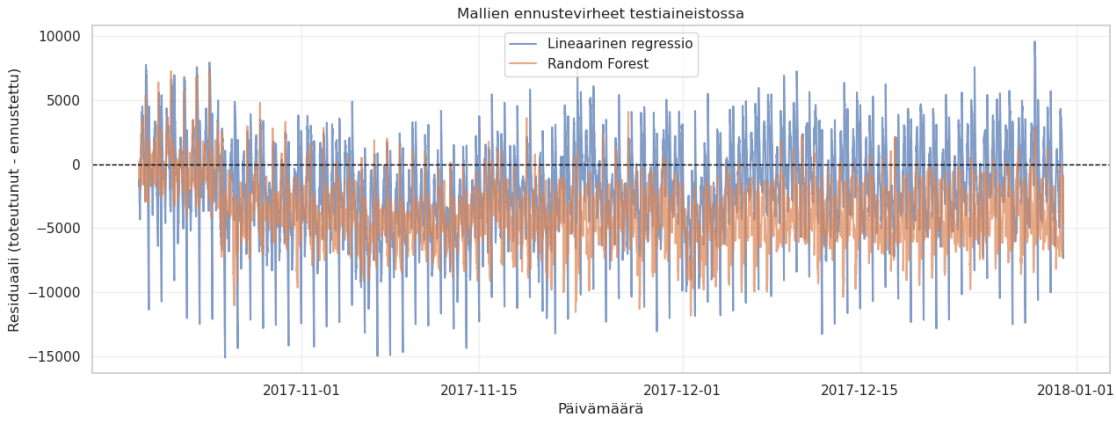
plt.plot(
    testiajat,
    residuaalit_linear,
    label="Lineaarinen regressio",
    alpha=0.7
)

plt.plot(
    testiajat,
    residuaalit_rf,
    label="Random Forest",
    alpha=0.7
)

# Nollataso tarkoittaa virheetöntä ennustetta
plt.axhline(0, color="black", linestyle="--", linewidth=1)

plt.title("Mallien ennustevirheet testiaineistossa")
plt.xlabel("Päivämäärä")
plt.ylabel("Residuaali (toteutunut - ennustettu)")
plt.legend()
plt.grid(alpha=0.3)

plt.tight_layout()
plt.show()
```



Residuaalikuvaajan tulkinta

Residuaalikuvaajassa lineaarisen regression ennustevirheet vaihtelevat voimakkaasti nollan molemmin puolin. Mallilla esiintyy sekä yli- että aliarviointeja.

Random Forest -mallin residuaalit ovat suuren osan testijaksosta negatiivisia. Tämä tarkoittaa, että malli ennustaa sähkönkulutuksen usein toteutunutta suuremmaksi.

Molempien mallien ennustevirheissä näkyy ajallista vaihtelua ja järjestelmällisiä piirteitä.

Random Forest -mallin taipumus yliarvioida kulutusta voi osaltaan selittää sen suurempia MAE- ja RMSE-arvoja.

8. Johtopäätökset

Sähkönkulutuksen vaihtelu

Visualisointien perusteella sähkönkulutuksessa esiintyy selvää vuorokausi- ja vuodenaikavaihtelua. Kulutus on suurimmillaan kesällä ja pienimmillään loppuvuodesta. Vuorokauden aikana kulutus on alhaisimmillaan aamuyöllä ja korkeimmillaan noin klo 20. Sunnuntaisin sähkönkulutus on keskimäärin pienempää kuin muina viikonpäivinä.

Epälineaariset yhteydet

Aineistossa näkyy mahdollisia epälineaarisia yhteyksiä. Erityisesti vuorokaudenajan ja sähkönkulutuksen välinen yhteys ei ole lineaarinen. Myös lämpötilan ja sähkönkulutuksen välillä esiintyy epälineaarisia piirteitä. Ilmankosteuden yhteys sähkönkulutukseen on epäselvempi.

Mallien vertailu

Lineaarinen regressio ennusti sähkönkulutusta paremmin kuin Random Forest tällä testiaineistolla.

Lineaarisen regression MAE oli 3246,51 ja RMSE 4075,93. Random Forest -mallin MAE oli 4304,93 ja RMSE 4758,18.

MAE- ja RMSE-arvojen merkitys

MAE kuvaa ennusteiden keskimääräistä absoluuttista virhettä, kun taas RMSE painottaa suurempia ennustevirheitä.

Lineaarisen regression MAE oli 3246,51 ja RMSE 4075,93. Random Forest -mallin MAE oli 4304,93 ja RMSE 4758,18. Lineaarinen regressio saavutti pienemmät virhearvot molemmilla mittareilla.

RMSE ja MAE suhde oli lineaarisella regressiolla noin 1,26 ja Random Forestilla noin 1,11.

Lineaarisen regression suurempi suhdeluku viittaa siihen, että sen virheiden joukossa esiintyy suhteellisesti enemmän suuria yksittäisiä poikkeamia.

Random Forest -mallin pienempi suhdeluku viittaa tasaisempaan virhejakaumaan. Residuaalikuvaajan perusteella sen ongelmana näyttää olevan erityisesti järjestelmällinen sähkönkulutuksen yliarviointi.

Vaikka Random Forestin virheet ovat suhteellisesti tasaisempia, sen keskimääräiset ennustevirheet ovat suuremmat kuin lineaarisella regressiolla.

Ennuste- ja residuaalikuvaajat

Ensimmäisen testiviikon kuvaajassa Random Forest seurasi sähkönkulutuksen nopeita muutoksia ja kulutushuippuja usein tarkemmin kuin lineaarinen regressio. Koko testijakson residuaalikuvaajassa Random Forest kuitenkin yliarvioi sähkönkulutusta suuren osan ajasta.

Lineaarisen regression ennustevirheet vaihtelivat enemmän nollan molemmin puolin.

Mahdolliset syyt mallien eroihin

Yksi mahdollinen syy Random Forest -mallin heikompaan tulokseen on aineiston ajallinen jakaminen. Opetusaineisto kattaa tammikuun ja lokakuun välisen ajan, kun taas testiaineisto sisältää lokakuun loppuosan sekä marras- ja joulukuun havaintoja.

Random Forest perustuu päätöspuihin, jotka eivät yleensä pysty ekstrapoloimaan eli ennustamaan opetusaineiston ulkopuolelle samalla tavalla kuin lineaarinen regressio. Opetusaineistossa kuukausimuuttujan suurin arvo on 10, mutta testiaineistossa esiintyvät myös kuukaudet 11 ja 12. Päätöspuut voivat siksi käsitellä loppuvuoden havaintoja samankaltaisesti kuin lokakuun havaintoja, vaikka sähkönkulutus on loppuvuonna pienempää.

Tämä voi selittää Random Forest -mallin järjestelmällistä yliarviointia, joka näkyy residuaalikuvaajassa pääosin negatiivisina ennustevirheinä.

Lineaarinen regressio pystyy puolestaan jatkamaan kuukausimuuttujan perusteella oppimaansa laskevaa yhteyttä myös myöhemmille kuukausille. Tämä on voinut auttaa sitä ennustamaan loppuvuoden sähkönkulutusta paremmin.

Myös lämpötilan ja muiden sääolosuhteiden muutokset voivat vaikuttaa mallien tarkkuuteen. Tulokset eivät kuitenkaan yksin osoita, mikä yksittäinen muuttuja selittää mallien välisen eron.

Voidaanko samaa mallia pitää aina parempana?

Ei voida. Mallien paremmuus riippuu aineistosta, valituista muuttujista, mallin asetuksista ja testausmenetelmästä.

Tässä tehtävässä lineaarinen regressio oli parempi, mutta toisella aineistolla tai erilaisilla malliasetuksilla Random Forest voisi saavuttaa paremman tuloksen.